

AI 프로그래밍

- 2주차



인하 공전 컴퓨터 정보과
민 정혜

- 지난 주 내용 복습
- 머신 러닝 (machine learning)
- 회귀 (regression)
- 선형 회귀 실습 (linear regression)

교재


■ 주교재

- 모두의 딥러닝,길벗, 2020




■ 부교재

- 딥러닝 express, 생능 출판사, 2021
- 부분적으로 사용할 계획



인공 지능 이란

- **인공 지능 (Artificial Intelligence)**
 - 인간이 가진 **지적 능력**을 **컴퓨터**를 통해 구현 하는 기술
- **머신 러닝 (Machine Learning)**
 - 데이터와 **알고리즘**을 통해 컴퓨터를 **학습** 시켜 인공 지능의 성능을 향상 시키는 기술
- **딥 러닝 (Deep Learning)**
 - **신경망 (Neural Network)** 을 이용한 머신 러닝 방법.
 - 여러 층으로 이루어진 신경망을 사용.



Machine Learning: A Primer to Laboratory Applications (thermofisher.com)



<https://m.blog.naver.com/pwj6971/221614497987>

인공 지능 적용 분야

자율주행 자동차

테슬라, 현대 자동차



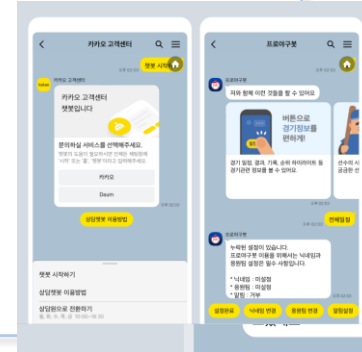
AI 비서

AI 스피커, 가상 비서



챗봇

AS 상담 챗봇, 호텔 예약 챗봇



로봇

청소로봇, 교육용 로봇




영상 인식

얼굴 인식, 번호판 인식,



개인화 추천

영화 추천, 광고 추천,
상품 추천, 게임 운영



기계 번역

구글 번역, 네이버, 파파고

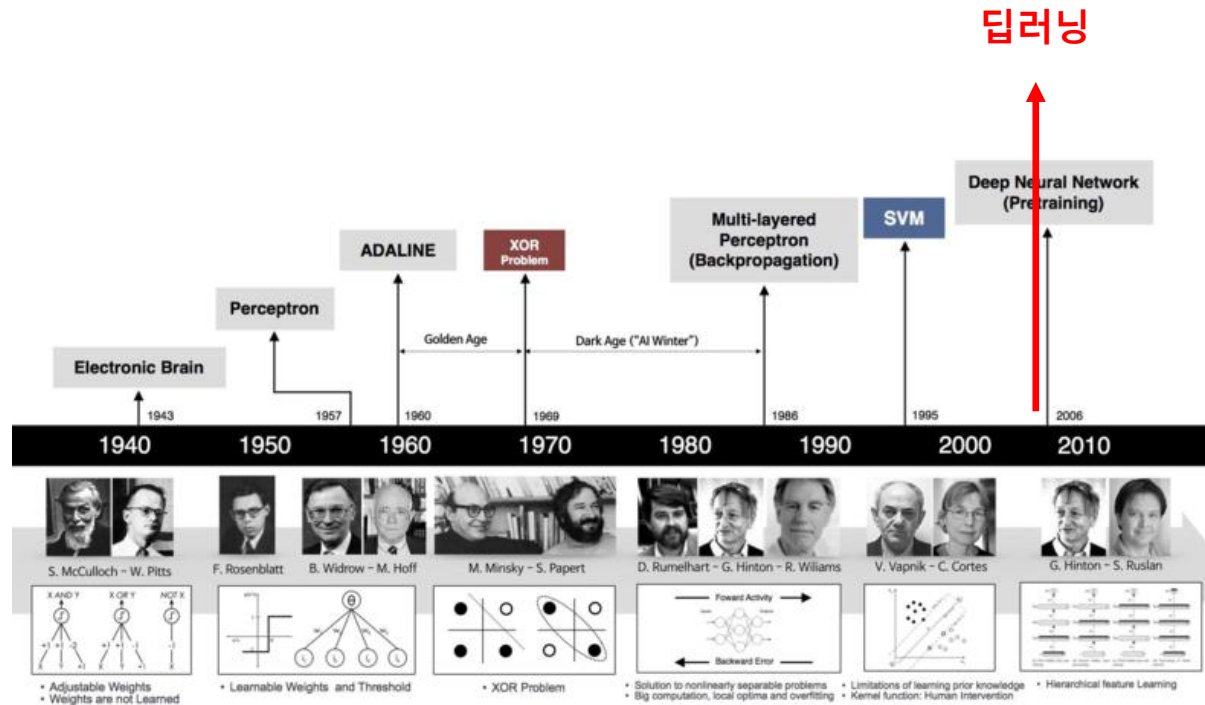


의료

질병 진단



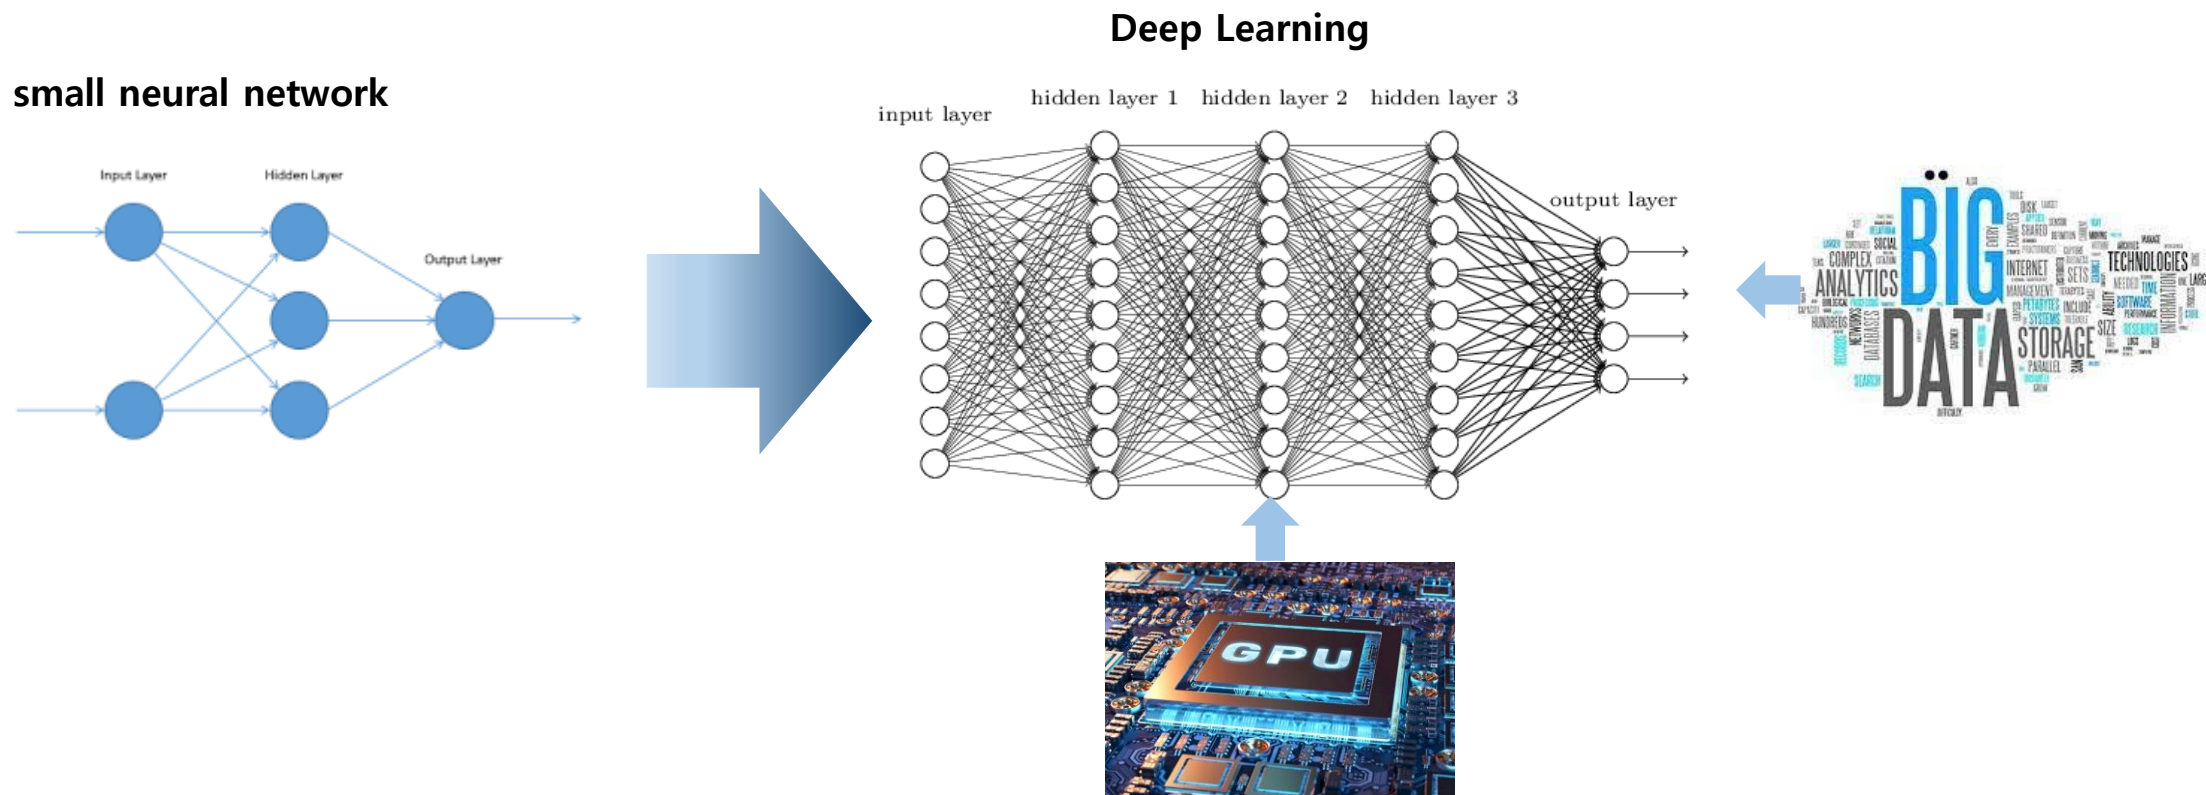
- 1950년대에 **인공 지능의 개념**과 신경망의 기본 개념인 **퍼셉트론** 개념이 성립됨.
- 2000년까지 신경망을 사용하지 않은 머신 러닝 사용됨.
- 2006년부터 신경망을 이용한 딥 러닝 (Deep Learning)이 급속히 발전함.

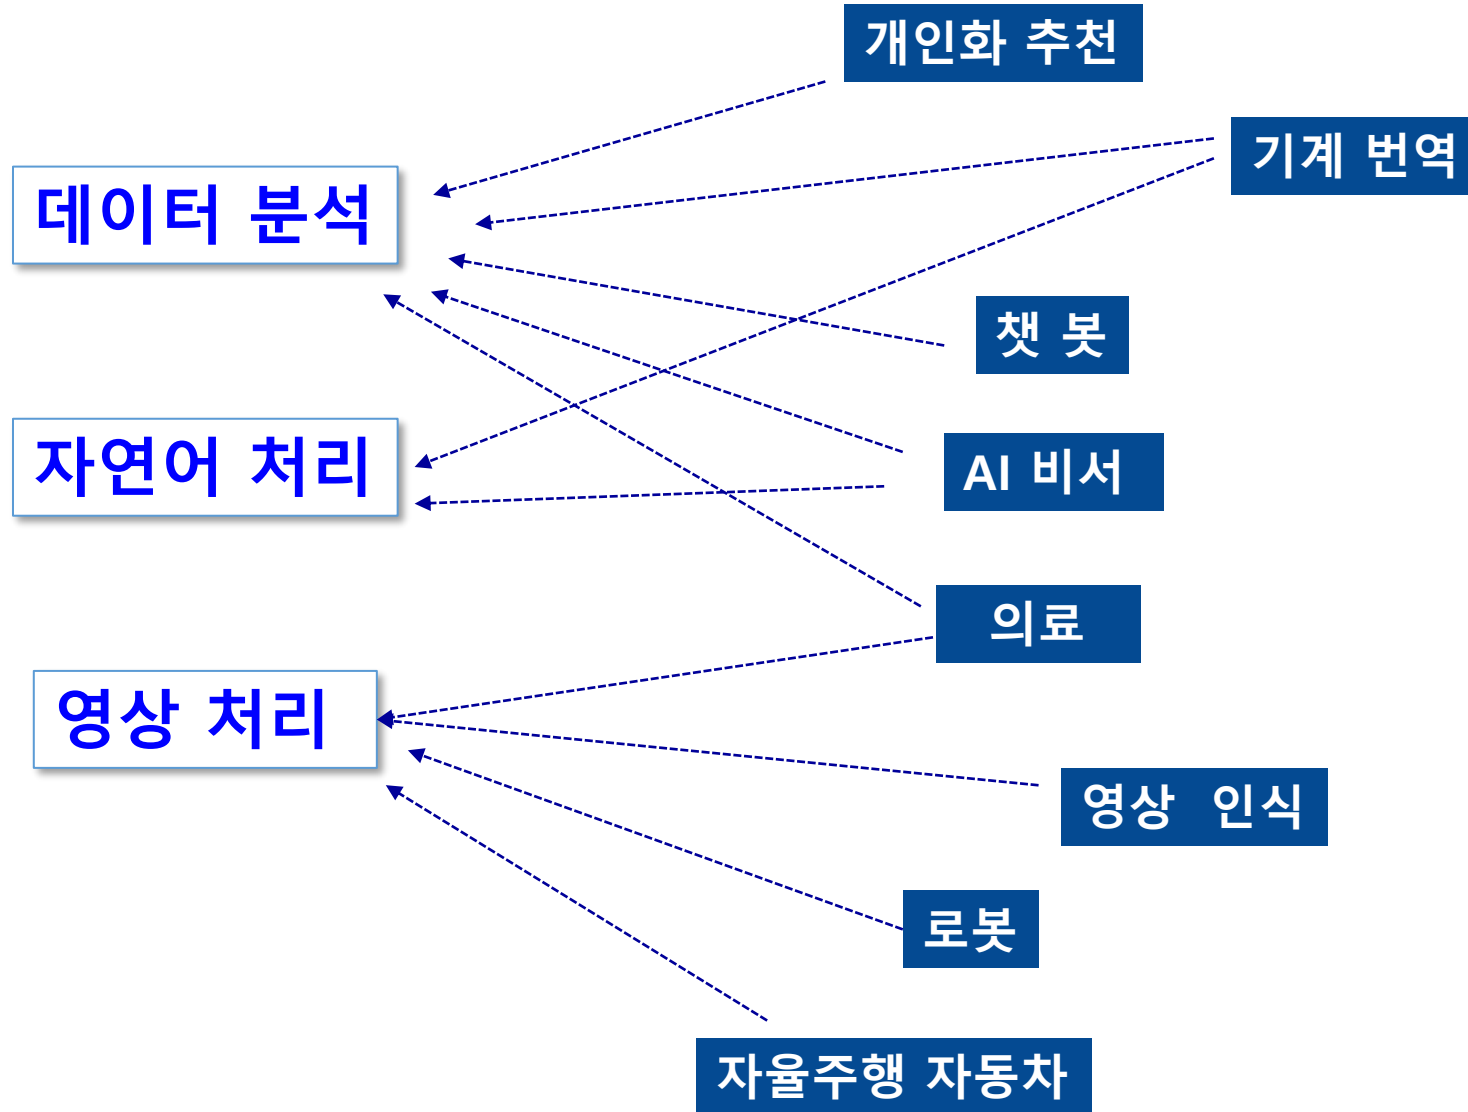


딥 러닝 (Deep Learning) 발전 이유

인하공전 컴퓨터 정보과

- **하드웨어의 발전**. 강력한 **GPU**는 딥러닝에서 복잡한 연산에 소요되는 시간을 크게 단축
- **빅 데이터**. 대량으로 쏟아져 나오는 데이터들을 학습에 활용 가능
- 신경망 이론의 단점 해결





2010 년 이전

- 기본 수식 구현 부터 대부분의 기능을 **C로 구현**
- 프로그래밍 **환경 설정이 쉬움.**

Summary: the equations of backpropagation

$$\delta^L = \nabla_a C \odot \sigma'(z^L) \quad (\text{BP1})$$

$$\delta^l = ((w^{l+1})^T \delta^{l+1} + \dots)$$

$$\frac{\partial C}{\partial b_j^l} = \delta_j^l$$

$$\frac{\partial C}{\partial w_{jk}^l} = a_k^{l-1} \delta_j^l$$

```
main <- function() {  
  header <- c("sepal_length", "sepal_width", "petal_length", "petal_width", "class")  
  iris <- read.csv("https://archive.ics.uci.edu/ml/machine-learning-databases/iris/iris.data")  
  names(iris) <- header  
  sample <- sample.int(n = nrow(iris), size = floor(.75*nrow(iris)), replace = F)  
  train <- iris[sample, ]  
  test <- iris[-sample, ]  
  
  cl <- makePSOCKcluster(3)  
  registerDoParallel(cl)  
  lr <- multinom(class ~., data = train)  
  lda_model <- lda(class ~., data = train)  
  
  man_grid <- expand.grid(k = c(1:10))  
  ctrl <- trainControl(method="cv", number = 5)  
  knn <- train(class ~., data = train, method = "knn", trControl = ctrl, tuneGrid = man_grid)  
  
  man_grid <- expand.grid(cost = c(1:10))  
  ctrl <- trainControl(method="cv", number = 5)  
  svm <- train(class ~., data = train, method = "svmLinear2", trControl = ctrl, tuneGrid = man_grid)  
  
  stopCluster(cl)  
  
  # Evaluate  
  lr_accuracy <- sum(predict(lr, test) == test$class) / nrow(test)  
  lda_accuracy <- sum(predict(lda_model, test)$class == test$class) / nrow(test)  
  knn_accuracy <- sum(predict(knn, test) == test$class) / nrow(test)  
  svm_accuracy <- sum(predict(svm, test) == test$class) / nrow(test)  
  print(paste(lr_accuracy, ",", lda_accuracy, ",", knn_accuracy, ",", svm_accuracy))  
}
```

2010 년 이후

- 파이썬 기반으로 다양한 **라이브러리** 사용 가능
- 대부분의 기능이 라이브러리에 함수로 구현되어 있음.
- 목적에 따라서 라이브러리를 선택 하여 구현
- 프로그래밍 환경 설정이 복잡함



머신러닝

 TensorFlow

 Keras

 PYTORCH
pytorch

 scikit learn
Scikit learn

데이터 분석

 pandas

 seaborn

 Matplotlib

자연어 처리

 spaCy

 Transformers
Hugging face

영상 처리

 OpenCV

 pillow

- 데이터와 알고리즘을 통해 컴퓨터를 학습 시켜 인공 지능의 성능을 향상 시키는 기술


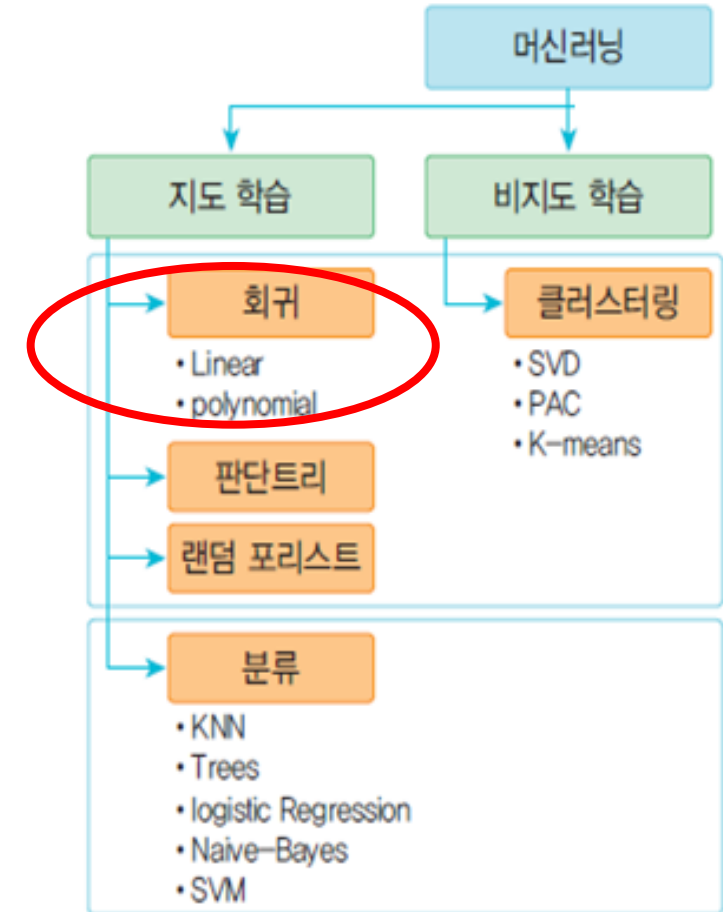
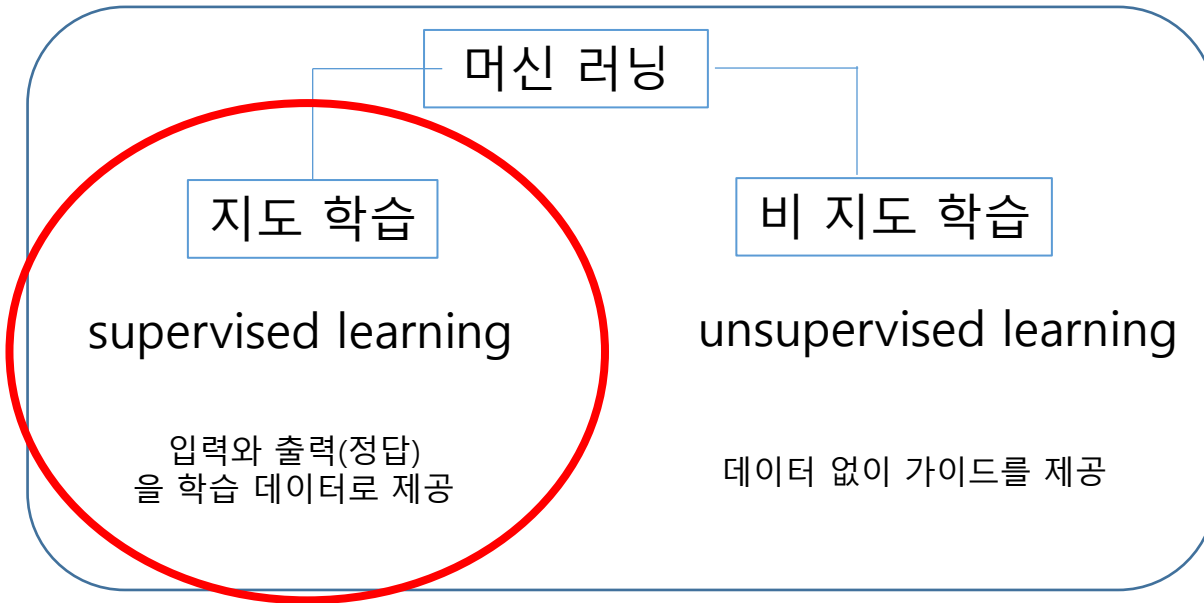
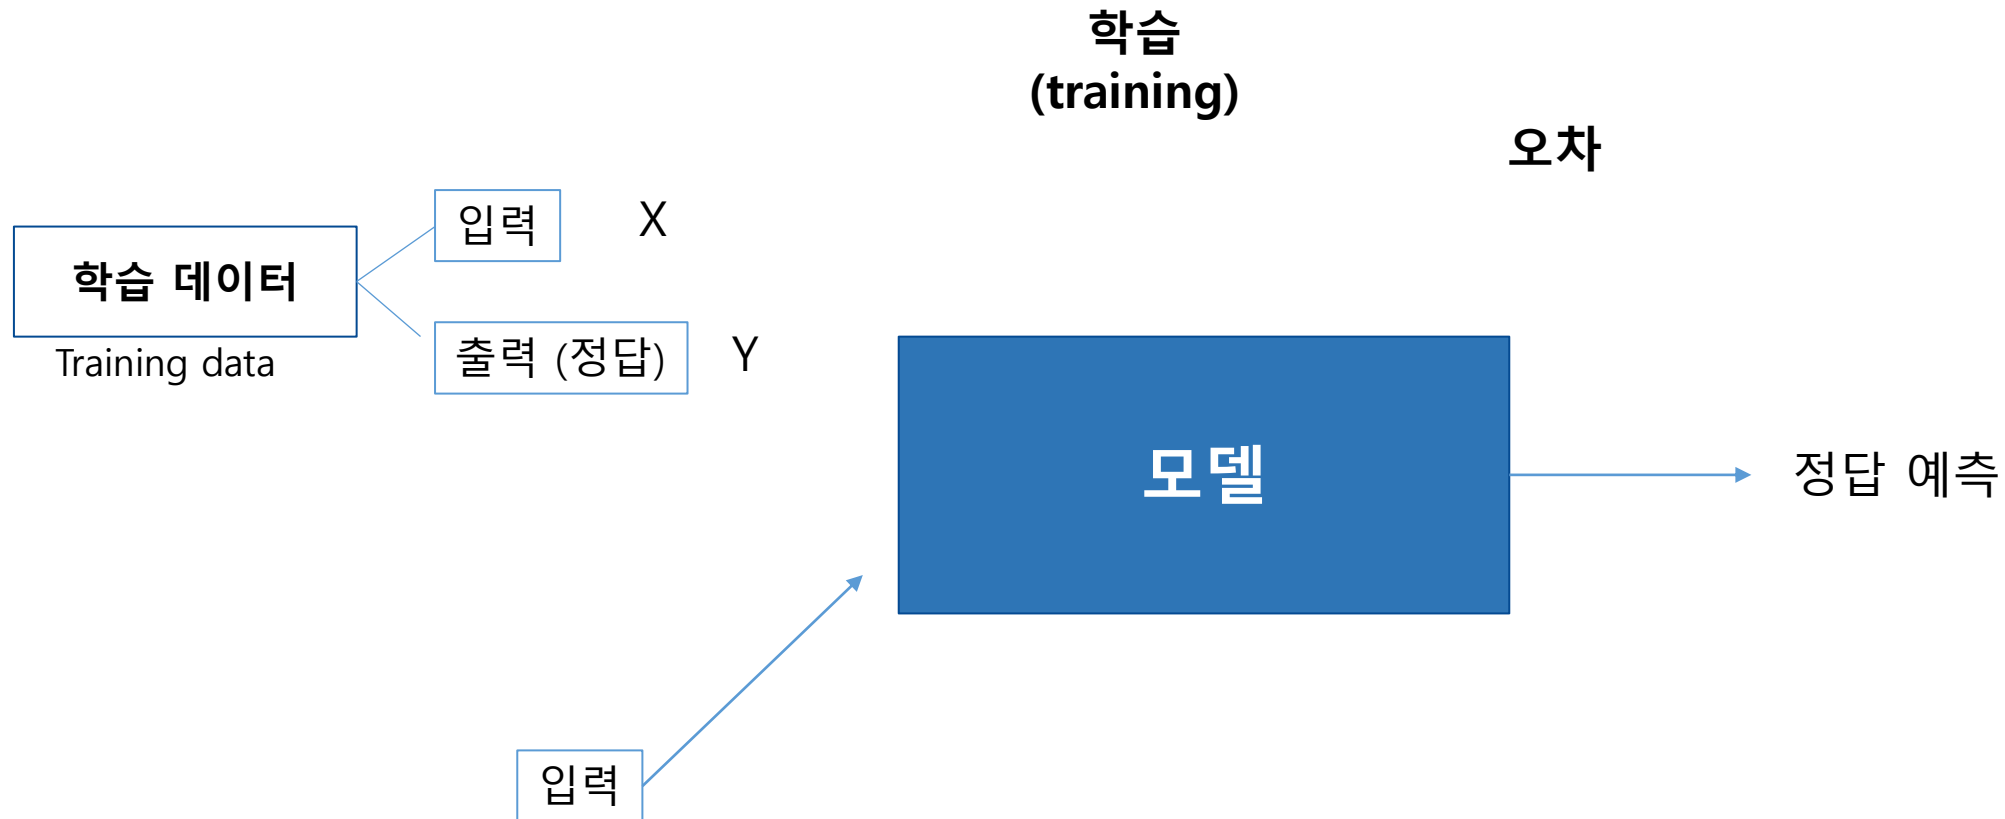
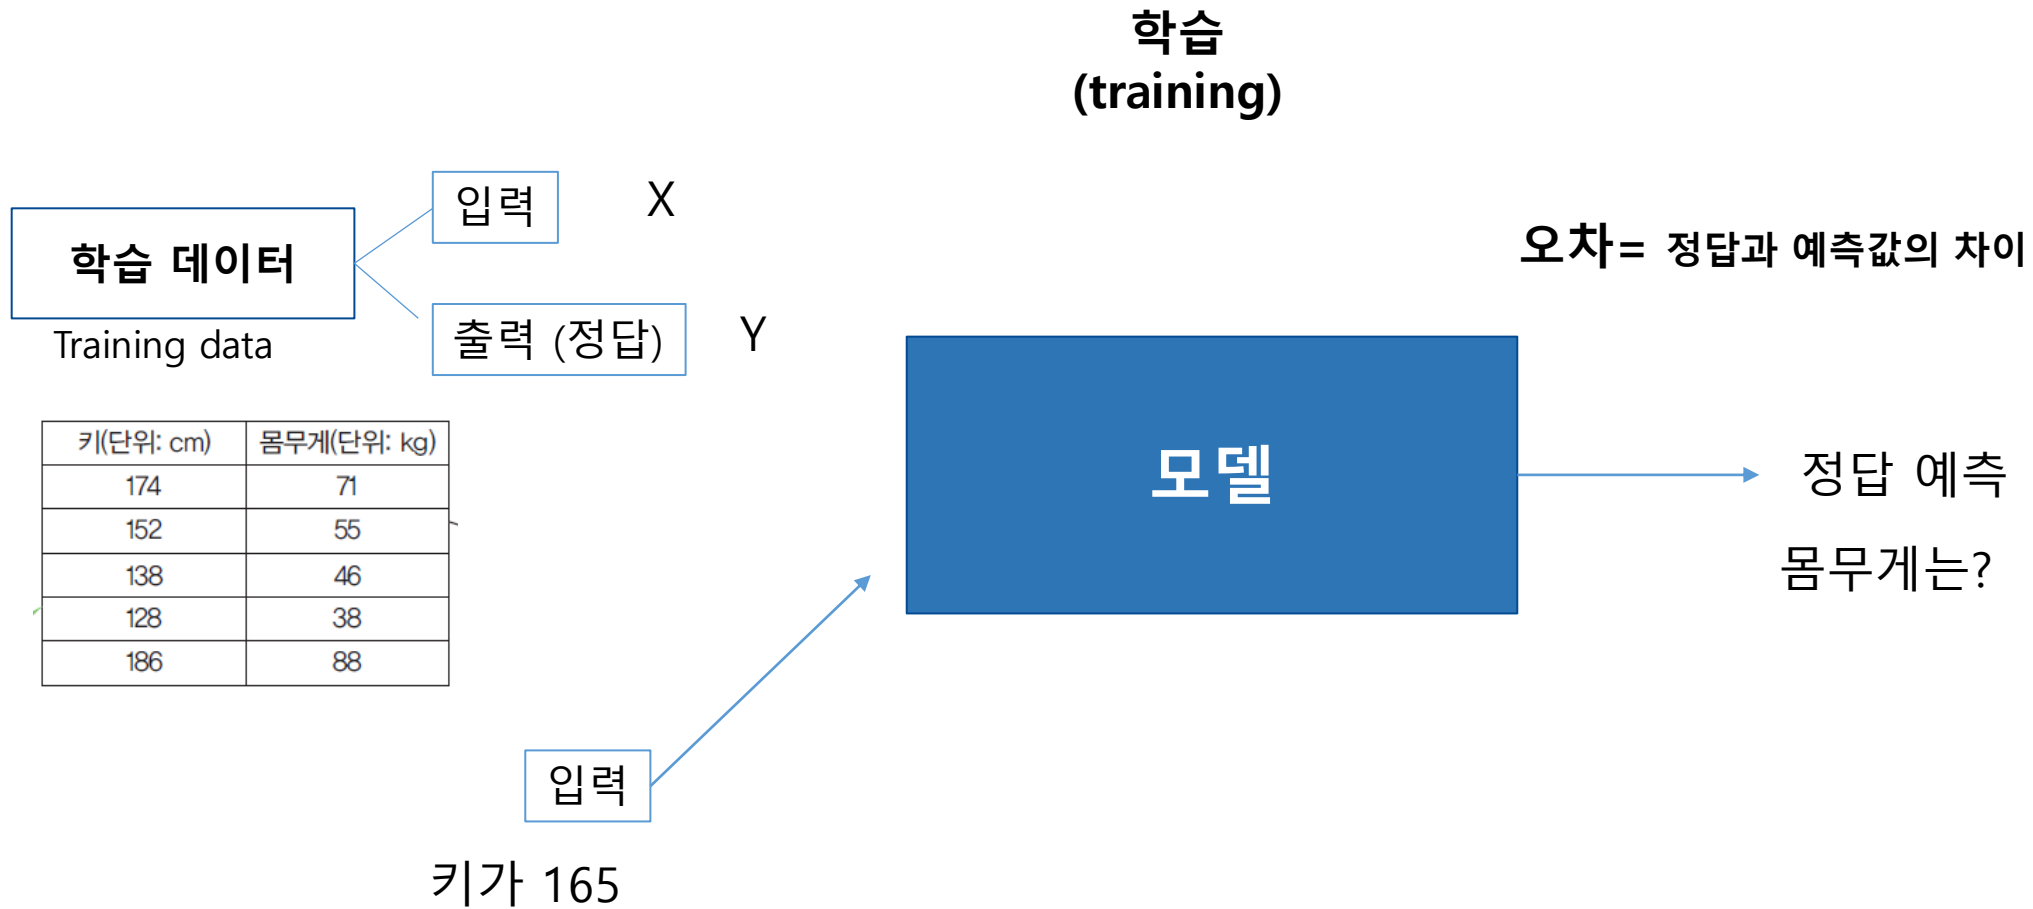


그림 3-2 전통적인 프로그래밍과 머신러닝의 차이점

참고자료 : 딥러닝 express







회귀 (regression)

- 데이터를 이용하여 결과를 예측 하는 함수를 도출 $y=f(x)$

- 선형 회귀

- 입력 값 x 가 1차원일때
- 직선의 방정식
- $Y=ax+b$

$\Rightarrow Y=wx+b$, w : weight, b : bias

| 키(단위: cm) | 몸무게(단위: kg) |
|-----------|-------------|
| 174 | 71 |
| 152 | 55 |
| 138 | 46 |
| 128 | 38 |
| 186 | 88 |




그림 4-2 회귀의 종류

참고자료 : 딥러닝 express

| | | | | |
|--------|------|------|------|------|
| 공부한 시간 | 2 | 4 | 6 | 8 |
| 성적 | 81 | 93 | 91 | 97 |
| 예측 값 | 83.6 | 88.2 | 92.8 | 97.4 |

선형 회귀 예제

- 공부한 시간(x)과 성적 (y)
- $Y=wx+b$ 로 예측
- 오차를 최소화 하는 w와 b 찾기

| | | | | |
|--------|------|------|------|------|
| 공부한 시간 | 2 | 4 | 6 | 8 |
| 성적 | 81 | 93 | 91 | 97 |
| 예측 값 | 83.6 | 88.2 | 92.8 | 97.4 |




그림 3-4 공부한 시간과 성적의 관계도




그림 3-5 임의의 직선 그려보기




그림 3-6 임의의 직선과 실제 값 사이의 거리

오차




그림 3-7 기울기를 너무 크게 잡았을 때의 오차




그림 3-8 기울기를 너무 작게 잡았을 때의 오차

| X | Y |
|---|-----|
| 0 | 3 |
| 1 | 3.5 |
| 2 | 5.5 |




그림 4-5 데이터와 직선 간의 거리

```
import numpy as np
import matplotlib.pyplot as plt
```

```
X = np.array([0.0, 1.0, 2.0])
y = np.array([3.0, 3.5, 5.5])
```

```
w = 0    # 기울기
b = 0    # 절편
```

```
lrate = 0.01 # 학습률
epochs = 1000 # 반복 횟수
```

```
n = float(len(X)) # 입력 데이터의 개수
```

```
# 경사 하강법
for i in range(epochs):
    y_pred = w*X + b
    dw = (2/n) * sum(X * (y_pred-y))
    db = (2/n) * sum(y_pred-y)
    w = w - lrate * dw
    b = b - lrate * db
```


```
# 기울기와 절편을 출력한다.
print (w, b)
```

```
# 예측값을 만든다.
y_pred = w*X + b
```

```
# 입력 데이터를 그래프 상에 찍는다.
plt.scatter(X, y)
```

```
# 예측값은 선그래프로 그린다.
plt.plot([min(X), max(X)], [min(y_pred), max(y_pred)], color='red')
plt.show()
```

```
# 선형 회귀 예측값
# 넘파이 배열간의 산술 계산은 요소별로 적용
# sum()은 모든 요소들의 합을 계산하는 내장 함수
# 기울기 수정
# 절편 수정
```



```
import numpy as np
import matplotlib.pyplot as plt
```

```
def mse(y,y_hat):
    return ((y-y_hat)**2).mean()
```

```
def mse_val(y,predict_result):
    return mse(np.array(y),np.array(predict_result))
```

```
X = np.array([0.0, 1.0, 2.0])
y = np.array([3.0, 3.5, 5.5])
```

```
w = 0      # 기울기
b = 0      # 절편
```

```
lr = 0.01 # 학습률
epochs = 500 # 반복 횟수
```

```
n = float(len(X)) # 입력 데이터의 개수
```

```
# 경사 하강법
for i in range(epochs):
    y_pred = w*X + b      # 선형 회귀 예측값
    dw = (2/n) * sum(X * (y_pred-y)) # 넘파이 배열간의 산술 계산은 요소별로 적용
    db = (2/n) * sum(y_pred-y)      # sum()은 모든 요소들의 합을 계산하는 내장 함수
    w = w - lr * dw      # 기울기 수정
    b = b - lr * db      # 절편 수정
    if (i%50==0):
        print('iteration %3d: loss  %4.2f w %3.2f b %3.2f'%(i,mse(y,y_pred),w,b))
```

```
# 기울기와 절편을 출력한다.
print ('##### final w,b',w, b)
```

```
# 예측값을 만든다.
y_pred = w*X + b
```

```
# 입력 데이터를 그래프 상에 찍는다.
plt.scatter(X, y)
```

```
# 예측값은 선그래프로 그린다.
plt.plot([min(X), max(X)], [min(y_pred), max(y_pred)], color='red')
plt.show()
```

첫번째 loss 값과 w,b 값을 저에게 채팅으로 보내 주세요.

| x | Y |
|---|-----|
| 0 | 3 |
| 1 | 3.5 |
| 2 | 5.5 |
| | |

```
import matplotlib.pyplot as plt
from sklearn import linear_model
```

```
# 선형 회귀 모델을 생성한다.
reg = linear_model.LinearRegression()
```

```
# 데이터는 파이썬의 리스트로 만들어도 되고 아니면 넘파이의 배열로 만들어도 됨
X = [[0], [1], [2]]          # 반드시 2차원으로 만들어야 함
y = [3, 3.5, 5.5]           # y = x + 3
```

```
# 학습을 시킨다.
reg.fit(X, y)
```

```
print(reg.coef_)              # 직선의 기울기
print(reg.intercept_)         # 직선의 y-절편
print(reg.score(X, y))
```

```
print(reg.predict([[5]]))
```

```
# 학습 데이터와 y 값을 산포도로 그린다.
plt.scatter(X, y, color='black')
```

```
# 학습 데이터를 입력으로 하여 예측값을 계산한다.
y_pred = reg.predict(X)
```

```
# 학습 데이터와 예측값으로 선그래프로 그린다.
# 계산된 기울기와 y 절편을 가지는 직선이 그려진다.
plt.plot(X, y_pred, color='blue', linewidth=3)
plt.show()
```





그림 4-5 데이터와 직선 간의 거리



| 키(단위: cm) | 몸무게(단위: kg) |
|-----------|-------------|
| 174 | 71 |
| 152 | 55 |
| 138 | 46 |
| 128 | 38 |
| 186 | 88 |

키가 160일때의 몸무게 예측 값을
보내 주세요

```
import matplotlib.pyplot as plt
from sklearn import linear_model
```

```
reg = linear_model.LinearRegression()
```

```
X = [[174], [152], [138], [128], [186]]
y = [71, 55, 46, 38, 88]
```

```
reg.fit(X, y) # 학습
```


```
print(reg.predict([[165]]))
```

```
# 학습 데이터와 y 값을 산포도로 그린다.
plt.scatter(X, y, color='black')
```



```
# 학습 데이터를 입력으로 하여 예측값을 계산한다.
y_pred = reg.predict(X)
```

```
# 학습 데이터와 예측값으로 선그래프로 그린다.
# 계산된 기울기와 y 절편을 가지는 직선이 그려진다.
plt.plot(X, y_pred, color='blue', linewidth=3)
plt.show()
```

[67.30998637]



- 부모의 키와 자녀의 키의 관계 조사
- 면적에 따른 주택의 가격
- 연령에 따른 실업율 예측
- 공부 시간과 학점 과의 관계
- CPU 속도와 프로그램 실행 시간 예측



참고자료 : 딥러닝 express

■ import numpy as np

```
a = np.arange(10)
print(a)
# [0 1 2 3 4 5 6 7 8 9]

print(a[4:8])
# [4 5 6 7]

print(a[-5:-2])
# [5 6 7]

print(a[::-1])
# [9 8 7 6 5 4 3 2 1 0]
```

```
a[3:6] = 100
print(a)
# [ 0  1  2 100 100 100  6  7  8  9]

a[3:6] = [100, 200, 300]
print(a)
# [ 0  1  2 100 200 300  6  7  8  9]
```

```
# a[3:6] = [100, 200, 300, 400]
# ValueError: cannot copy sequence with size 4 to array axis with
dimension 3
```

Numpy slicing

```
a = np.arange(10)
print(a)
# [0 1 2 3 4 5 6 7 8 9]

print(a[2:8:2])
# [2 4 6]

a[2:8:2] = 100
print(a)
# [ 0  1 100  3 100  5 100  7  8  9]

a[2:8:2] = [100, 200, 300]
print(a)
# [ 0  1 100  3 200  5 300  7  8  9]
```

```
a = np.arange(12).reshape((3, 4))  
print(a)  
# [[ 0  1  2  3]  
#   [ 4  5  6  7]  
#   [ 8  9 10 11]]
```

```
print(a[1:, 1:3])  
# [[ 5  6]  
#   [ 9 10]]
```

```
print(a[1:, :])  
# [[ 4  5  6  7]  
#   [ 8  9 10 11]]  
  
print(a[1:])  
# [[ 4  5  6  7]  
#   [ 8  9 10 11]]
```

```
a = np.arange(12).reshape((3, 4))
print(a)
# [[ 0  1  2  3]
#   [ 4  5  6  7]
#   [ 8  9 10 11]]

print(a[1:, 1:3])
# [[ 5  6]
#   [ 9 10]]

a[1:, 1:3] = 100
print(a)
# [[ 0  1  2  3]
#   [ 4 100 100  7]
#   [ 8 100 100 11]]

a[1:, 1:3] = [100, 200]
print(a)
# [[ 0  1  2  3]
#   [ 4 100 200  7]
#   [ 8 100 200 11]]

a[1:, 1:3] = [[100, 200], [300, 400]]
print(a)
# [[ 0  1  2  3]
#   [ 4 100 200  7]
#   [ 8 300 400 11]]
```

indexing으로 길이가 1인 새로운 축 추가
: arr[:, np.newaxis, :]

```
a = np.array([1., 2., 3., 4.])
```

shape : (4,)



a[:, np.newaxis]

```
array([[1.],  
       [2.],  
       [3.],  
       [4.]])
```

shape : (4, 1)

```
import numpy as np
```

```
arr = np.array([1, 2, 3, 4])
```

```
arr1=arr
```

```
arr2=arr[np.newaxis]
```

```
arr3=arr[:, np.newaxis]
```

```
print(arr1,arr1.shape)
```

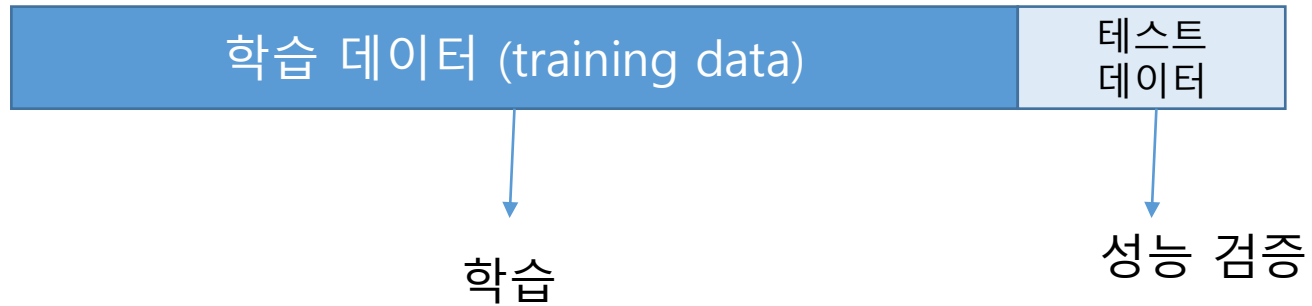
```
print(arr2,arr2.shape)
```

```
print(arr3,arr3.shape)
```

```
arr1 [1 2 3 4] (4,)
```

```
arr2 [[1 2 3 4]] (1, 4)
```

```
arr3 [[1] [2] [3] [4]] (4, 1)
```



선형 회귀 예제 실습 - 당뇨병 예제

인하공전 컴퓨터 정보과

| | | | | | | | | | | | |
|---------|-----|-----|----|----|----|----|----|----|----|--------------------|-----|
| 특징(10개) | | | | | | | | | | 데이터 개수 (442) | 혈당 |
| age | sex | bmi | bp | s1 | s2 | s3 | s4 | s5 | s6 | | |
| | | | | | | | | | | | |
| | | | | | | | | | | | |
| ... | | | | | | | | | | | ... |
| | | | | | | | | | | | |

Bmi와 혈당간의 관계 예측

```
import matplotlib.pyplot as plt
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn import datasets, linear_model

# 당뇨병 데이터 세트를 적재한다.
diabetes_X, diabetes_y = datasets.load_diabetes(return_X_y=True)

print(diabetes_X.data.shape )
# 하나의 특징(BMI)만 추려내서 2차원 배열로 만든다. BMI 특징의 인덱스가 2이다.
diabetes_X_new = diabetes_X[:, np.newaxis, 2]
print(diabetes_X_new.data.shape )
```



```
import matplotlib.pyplot as plt
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn import datasets, linear_model

# 당뇨병 데이터 세트를 적재한다.
diabetes_X, diabetes_y = datasets.load_diabetes(return_X_y=True)

print(diabetes_X.data.shape )
# 하나의 특징(BMI)만 추려내서 2차원 배열로 만든다. BMI 특징의 인덱스가 2이다.
diabetes_X_new = diabetes_X[:, np.newaxis, 2]
print(diabetes_X_new.data.shape )

# 학습 데이터와 테스트 데이터를 분리한다.
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(diabetes_X_new, diabetes_y,
test_size=0.1, random_state=0)

regr = linear_model.LinearRegression()
regr.fit(X_train, y_train)

# 테스트 데이터로 예측해보자.
y_pred = regr.predict(X_test)

# 실제 데이터와 예측 데이터를 비교해보자.
# plt.plot(y_test, y_pred, '.')

plt.scatter(X_test, y_test, color='black')
plt.plot(X_test, y_pred, color='blue', linewidth=3)
plt.show()
```

수고 하셨습니다



jhmin@inhatec.ac.kr