

# AI 프로그래밍

- 11주차



인하 공전 컴퓨터 정보과  
민 정혜

- 케라스 딥러닝 복습
- 케라스 딥러닝 예제 실습
  - 타이타닉 생존자 예측
  - 패션 아이템 분류
  - 와인 품종 예측
  - 주택 가격 예측
- 영상 처리기초 : open cv

Tensorflow 2.8

# 케라스로 신경망을 작성 하는 절차

```
model = tf.keras.models.Sequential()
```

Sequential 모델을 생성

```
model.add(tf.keras.layers.Dense(units=2, input_shape=(2,), activation='sigmoid')) #①
```

```
model.add(tf.keras.layers.Dense(units=1, activation='sigmoid'))
```

Add함수를 이용하여 layer 추가

```
model.compile(loss='mean_squared_error', optimizer=keras.optimizers.SGD(lr=0.3)  
              , metrics='accuracy')
```

컴파일

```
model.fit(X, y, batch_size=1, epochs=10000)
```

학습을 수행

```
print( model.predict(X) )
```

모델 테스트

[Keras API reference](https://keras.io/api/)

<https://keras.io/api/>

```
model = tf.keras.models.Sequential()

model.add(tf.keras.layers.Dense(units=2, input_shape=(2,), activation='sigmoid')) #①
model.add(tf.keras.layers.Dense(units=1, activation='sigmoid'))

model.compile(loss='mean_squared_error', optimizer=keras.optimizers.SGD(lr=0.3),
, metrics='accuracy'))

model.fit(X, y, batch_size=1, epochs=10000)

print( model.predict(X) )
```

- **피마 인디언 데이터 분석**

- 데이터 가공

- **아이리스 품종 예측**

- 다중 분류, 상관도 그래프, 원-핫 인코딩, 소프트 맥스

- **초음파 광물 예측**

- 과 적합 (Overfitting) 피하기, 교차 검증, 모델 저장과 재사용

|   | pregnant | plasma | pressure | thickness | insulin | BMI  | pedigree | age | class |
|---|----------|--------|----------|-----------|---------|------|----------|-----|-------|
| 0 | 6        | 148    | 72       | 35        | 0       | 33.6 | 0.627    | 50  | 1     |
| 1 | 1        | 85     | 66       | 29        | 0       | 26.6 | 0.351    | 31  | 0     |
| 2 | 8        | 183    | 64       | 0         | 0       | 23.3 | 0.672    | 32  | 1     |
| 3 | 1        | 89     | 66       | 23        | 94      | 28.1 | 0.167    | 21  | 0     |
| 4 | 0        | 137    | 40       | 35        | 168     | 43.1 | 2.288    | 33  | 1     |

당뇨병 여부 : 0, 1

## # 모델의 설정

```
model = Sequential()  
model.add(Dense(12, input_dim=8, activation='relu'))  
model.add(Dense(8, activation='relu'))  
model.add(Dense(1, activation='sigmoid'))
```

입력 층 : 8  
은닉층 1 : 12 ( relu)  
은닉층 2 : 8 (relu)  
출력 층 1 (sigmoid)

# 활성화 함수




그림 6-3 많이 사용되는 활성화 함수

범위

[0.0, 1.0]

범위

[-1.0, 1.1]

범위

[0.0. ~]

## ■ 아이리스 품종 예측

|   | sepal_length | sepal_width | petal_length | petal_width | species     |
|---|--------------|-------------|--------------|-------------|-------------|
| 0 | 5.1          | 3.5         | 1.4          | 0.2         | Iris-setosa |
| 1 | 4.9          | 3           | 1.4          | 0.2         | Iris-setosa |
| 2 | 4.7          | 3.2         | 1.3          | 0.2         | Iris-setosa |
| 3 | 4.6          | 3.1         | 1.5          | 0.2         | Iris-setosa |
| 4 | 5            | 3.6         | 1.4          | 0.2         | Iris-setosa |

- 문자열을 숫자로 바꿔 주려면 클래스 이름을 숫자 형태로 바꿔 주어야 함

```
from sklearn.preprocessing import LabelEncoder
```

```
e = LabelEncoder()
```

```
e.fit(Y_obj)
```

```
Y = e.transform(Y_obj)
```



## ■ 아이리스 품종 예측

```
from tensorflow.keras.utils import np_utils
```

```
Y_encoded = tf.keras.utils.to_categorical(Y)
```

- array([1,2,3])가 다시 array([[1., 0., 0.], [0., 1., 0.], [0., 0., 1.]])로 바뀜
- 원-핫 인코딩(one-hot-encoding) :

여러 개의 Y 값을 0과 1로만 이루어진 형태로 바꿔 주는 기법

# 케라스 딥러닝

```
Y_obj= array(['Iris-setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-  
setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-  
setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-  
setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-  
setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-  
setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-  
setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-  
setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-  
setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-  
setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-  
setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-  
setosa', 'Iris-setosa', 'Iris-setosa', 'Iris-versicolor',  
'Iris-versicolor', 'Iris-versicolor', 'Iris-versicolor',  
'Iris-versicolor',
```

```
Y= array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,  
        0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,  
        0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,  
        1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,  
        1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2,  
        2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2,  
        2, 2, 2, 2, 2, 2, 2, 2, 2])
```

```
Y_encoded      array([[1., 0., 0.], [1., 0., 0.], [1., 0., 0.], [1.,
0., 0.], [1., 0., 0.], [1., 0., 0.], [1., 0., 0.],
[1., 0., 0.], [1., 0., 0.]
```

```
from sklearn.preprocessing import LabelEncoder
```

```
e = LabelEncoder()
```

## 정수 인코딩

```
e.fit(Y_obj)
```

```
Y = e.transform(Y_obj)
```

```
from tensorflow.keras.utils import np_utils
```

```
Y_encoded = tf.keras.utils.to_categorical(Y)
```

원 핫 인코딩

# 케라스 딥러닝

```
import numpy as np
X = np.array(['Korea', 44, 7200],
             ['Japan', 27, 4800],
             ['China', 30, 6100])

from sklearn.preprocessing import LabelEncoder
labelencoder = LabelEncoder()
X[:, 0] = labelencoder.fit_transform(X[:, 0])
print(X)
```

```
[[2 44 7200]
 [1 27 4800]
 [0 30 6100]]
```

정수 인코딩

원 핫 인코딩

원-핫 인코딩은 단 하나의 값만 1이고 나머지는 모두 0인 인코딩을 의미한다.

| Country | Age | Salary |
|---------|-----|--------|
| Korea   | 38  | 7200   |
| Japan   | 27  | 4800   |
| China   | 30  | 3100   |

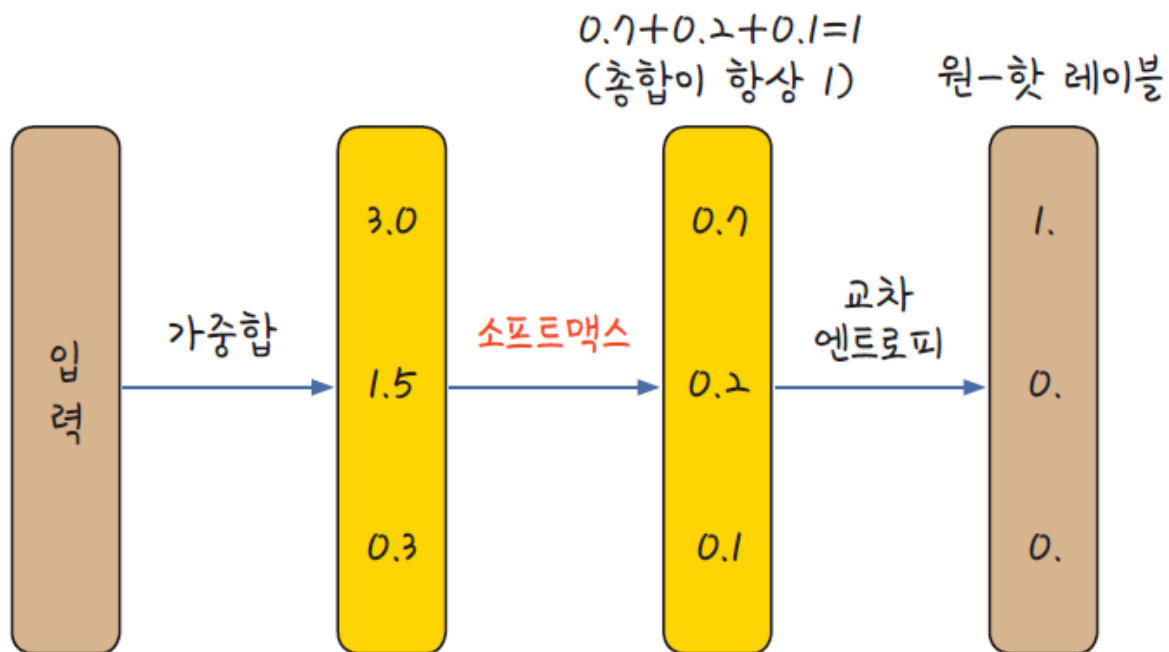


| Korea | Japan | China | Age | Salary |
|-------|-------|-------|-----|--------|
| 1     | 0     | 0     | 38  | 7200   |
| 0     | 1     | 0     | 27  | 4800   |
| 0     | 0     | 1     | 30  | 3100   |

# 케라스 딥러닝 - 소프트 맥스

- 소프트맥스 :

그림 12-3에서와 같이 총합이 1인 형태로 바뀌서 계산해 주는 함수



```
model = Sequential()  
model.add(Dense(16, input_dim=4, activation='relu'))  
model.add(Dense(3, activation='softmax'))
```

그림 12-3 소프트맥스 함수의 원리

- 과적합을 방지하려면 어떻게 해야 할까?

→ 먼저 학습을 하는 데이터셋과 이를 테스트할 데이터셋을 완전히 구분한 다음  
학습과 동시에 테스트를 병행하며 진행하는 것이 한 방법

- 데이터셋이 총 100개의 샘플로 이루어져 있다면 다음과 같이 두 개의 셋으로 나눔

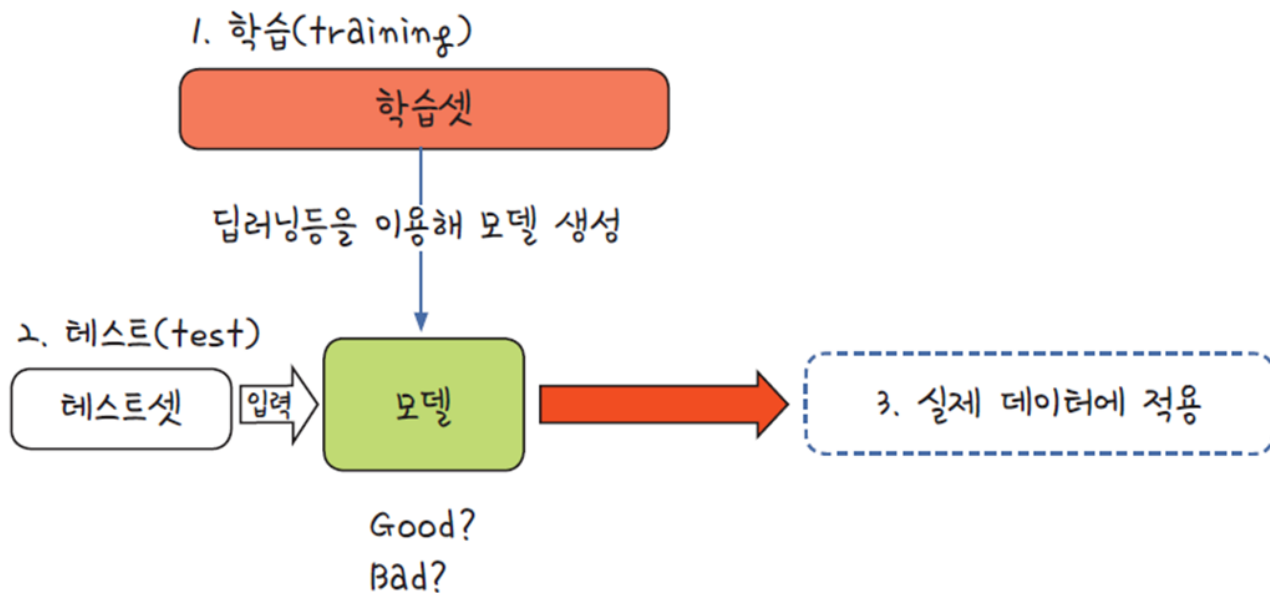
**학습셋 테스트 셋 구분**

70개 샘플은 학습셋으로

30개 샘플은 테스트셋으로

```
from sklearn.model_selection import train_test_split

# 학습셋과 테스트셋의 구분
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_
size=0.3, random_state=seed)
```




학습셋 테스트 셋 구분

```
model.fit(X_train, Y_train, epochs=130, batch_size=5)
```

# 테스트셋에 모델 적용

```
print("\n Test Accuracy: %.4f" % (model.evaluate(X_test, Y_test)<br/>[1]))
```

## 5 | k겹 교차 검증



## 모델 저장과 재사용

```
model.fit(X_train, Y_train, epochs=130, batch_size=5)
```

```
model.save('my_model.h5') # 모델을 컴퓨터에 저장
```

```
del model # 테스트를 위해 메모리 내의 모델을 삭제
```

```
model = load_model('my_model.h5') # 모델을 새로 불러옴
```

```
print("\n Test Accuracy: %.4f" % (model.evaluate(X_test, Y_test)  
[1])) # 불러온 모델로 테스트 실행
```



# 케라스 신경망 실습 - 타이타닉 생존자 예측

인하공전 컴퓨터 정보과



생존자를 예측해봅시다. 어떤 부류의  
사람들의 생존률이 높았을까요?  
우리는 어떤 속성을 이용하여 이것을  
예측할 수 있을까요?



Second



Third



Crew

# 케라스 신경망 실습 - 타이타닉 생존자 예측

인하공전 컴퓨터 정보과

PassengerId : 각 승객의 고유 번호

Survived : 생존 여부(종속 변수)

- 0 = 사망

- 1 = 생존

Pclass : 객실 등급 - 승객의 사회적, 경제적 지위

- 1st = Upper

- 2nd = Middle

- 3rd = Lower

Name : 이름

Sex : 성별

Age : 나이

SibSp : 동반한 Sibling(형제자매)와 Spouse(배우자)의 수

Parch : 동반한 Parent(부모) Child(자식)의 수

Ticket : 티켓의 고유번호

Fare : 티켓의 요금

Cabin : 객실 번호

Embarked : 승선한 항

- C = Cherbourg

- Q = Queenstown

- S = Southampton

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import tensorflow as tf
```

```
# 데이터 세트를 읽어들인다.
train = pd.read_csv("train.csv", sep=',')
test = pd.read_csv("test.csv", sep=',')

# 필요없는 컬럼을 삭제한다.
train.drop(['SibSp', 'Parch', 'Ticket', 'Embarked', 'Name', \
            'Cabin', 'PassengerId', 'Fare', 'Age'], inplace=True, axis=1)

# 결손치가 있는 데이터 행은 삭제한다.
train.dropna(inplace=True)
```

```
>>> train.drop(['SibSp', 'Parch', 'Ticket', 'Embarked', 'Name',\
                'Cabin', 'PassengerId', 'Fare', 'Age'], inplace=True, axis=1)
```

```
>>> train.head()
   Survived  Pclass    Sex
0         0       3   male
1         1       1  female
2         1       3  female
3         1       1  female
4         0       3   male
```

# 케라스 신경망 실습 - 타이타닉 생존자 예측

인하공전 컴퓨터 정보과

# 기호를 수치로 변환한다.

for ix in train.index:

if train.loc[ix, 'Sex']=="male":

train.loc[ix, 'Sex']=1

else:

train.loc[ix, 'Sex']=0

컴퓨터는 숫자만 처리할 수 있다.  
딥러닝은 0부터 1 사이의 실수만  
처리 가능

# 2차원 배열을 1차원 배열로 평탄화한다.

target = np.ravel(train.Survived)

# 생존여부를 학습 데이터에서 삭제한다.

train.drop(['Survived'], inplace=True, axis=1)

train = train.astype(float) # 최근 소스에서는 float형태로 형변환하여야

교과서 소스에 추  
가

```
# 케라스 모델을 생성한다.
model = tf.keras.models.Sequential()
model.add(tf.keras.layers.Dense(16, activation='relu', input_shape=(2,)))
model.add(tf.keras.layers.Dense(8, activation='relu'))
model.add(tf.keras.layers.Dense(1, activation='sigmoid'))

# 케라스 모델을 컴파일한다.
model.compile(loss='binary_crossentropy',
              optimizer='adam',
              metrics=['accuracy'])

# 케라스 모델을 학습시킨다.
model.fit(train, target, epochs=30, batch_size=1, verbose=1)
```

```
...  
Epoch 29/30  
891/891 [=====] - 1s 753us/sample - loss: 0.4591 - acc:  
0.7677  
Epoch 30/30  
891/891 [=====] - 1s 753us/sample - loss: 0.4547 - acc:  
0.7789
```

약 78% 정확도

```
idx=test.shape[0]
pred=model.predict(test)
test_np=test.to_numpy()
for i in range(idx):
    print(test_np[i,:],pred[i])
```

객실 등급, 성별, 생존 확률

```
[3. 1.] [0.11963955]
[3. 0.] [0.42622244]
[2. 1.] [0.20062831]
[3. 1.] [0.11963955]
[3. 0.] [0.42622244]
[3. 1.] [0.11963955]
[3. 0.] [0.42622244]
[2. 1.] [0.20062831]
[3. 0.] [0.42622244]
[3. 1.] [0.11963955]
[3. 1.] [0.11963955]
[1. 1.] [0.35509673]
[1. 0.] [0.9667859]
[2. 1.] [0.20062831]
[1. 0.] [0.9667859]
[2. 0.] [0.84050065]
[2. 1.] [0.20062831]
[3. 1.] [0.11963955]
[3. 0.] [0.42622244]
[3. 0.] [0.42622244]
[1. 1.] [0.35509673]
[3. 1.] [0.11963955]
[1. 0.] [0.9667859]
[1. 1.] [0.35509673]
[1. 0.] [0.9667859]
[3. 1.] [0.11963955]
```



과제                      titanic\_test.ipynb              test.csv, train.csv

모델을 다음과 같이 변경 하고 code (모델 생성 부분만 )과 정확도(accuracy)를 제출 하시오.

1)    입력 층 : 변동 없음  
     은닉층 1 : 16 ( relu)  
     은닉층 2 : 8 (relu)  
     은닉층 3 : 8 (relu)  
     출력 층   변동 없음.

2)    입력 층 : 변동 없음  
     은닉층 1 : 16 ( relu)  
     은닉층 2 : 16 (relu)  
     은닉층 3 : 8 (relu)  
     출력 층   변동 없음.

```
model.add(tf.keras.layers.Dense(16, activation='relu', input_shape=(2,)))
model.add(tf.keras.layers.Dense(8, activation='relu'))
model.add(tf.keras.layers.Dense(8, activation='relu'))
model.add(tf.keras.layers.Dense(1, activation='sigmoid'))
```

Model: "sequential\_2"

입력 층 : 2  
은닉층 1 : 16 ( relu)  
은닉층 2 : 8 (relu)  
은닉층 3 : 8 (relu)  
출력 층 : 1


| Layer (type)    | Output Shape | Param # |
|-----------------|--------------|---------|
| =====           |              |         |
| dense_6 (Dense) | (None, 16)   | 48      |
| dense_7 (Dense) | (None, 8)    | 136     |
| dense_8 (Dense) | (None, 8)    | 72      |
| dense_9 (Dense) | (None, 1)    | 9       |
| =====           |              |         |

Total params: 265  
Trainable params: 265  
Non-trainable params: 0

```
model.add(Dense(30, input_dim=12, activation='relu'))
model.add(Dense(12, activation='relu'))
model.add(Dense(8, activation='relu'))
model.add(Dense(1, activation='sigmoid'))
```

입력 층 : 12  
은닉층 1 : 30 ( relu)  
은닉층 2 : 12 (relu)  
은닉층 3 : 8 (relu)  
출력 층 : 1 (sigmoid)



| Layer (type)    | Output Shape | Param # |
|-----------------|--------------|---------|
| dense (Dense)   | (None, 30)   | 390     |
| dense_1 (Dense) | (None, 12)   | 372     |
| dense_2 (Dense) | (None, 8)    | 104     |
| dense_3 (Dense) | (None, 1)    | 9       |




- 이미지는 28x28 크기이고 픽셀 값은 0과 255 사이의 값이다. 레이블(label)은 0에서 9까지의 정수로서 패션 아이템의 범주를 나타낸다.

| 레이블 | 범주          |
|-----|-------------|
| 0   | T-shirt/top |
| 1   | Trouser     |
| 2   | Pullover    |
| 3   | Dress       |
| 4   | Coat        |
| 5   | Sandal      |
| 6   | Shirt       |
| 7   | Sneaker     |
| 8   | Bag         |
| 9   | Ankle boot  |


## ■ plt.imshow(train\_images[0])



두번째



네번째



28x28 gray image

```
import tensorflow as tf
from tensorflow import keras
import numpy as np
import matplotlib.pyplot as plt
from tensorflow.keras import datasets, layers, models

fashion_mnist = keras.datasets.fashion_mnist
(train_images, train_labels), (test_images, test_labels) = fashion_mnist.load_data()

plt.imshow(train_images[0])

train_images = train_images / 255.0
test_images = test_images / 255.0
```

```
model = models.Sequential()
model.add(layers.Flatten(input_shape=(28, 28)))
model.add(layers.Dense(128, activation='relu'))
model.add(layers.Dense(10, activation='softmax'))

model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

model.fit(train_images, train_labels, epochs=5)

test_loss, test_acc = model.evaluate(test_images, test_labels)
print('정확도:', test_acc)
```



```
model = models.Sequential()
model.add(layers.Flatten(input_shape=(28, 28)))
model.add(layers.Dense(128, activation='relu'))
model.add(layers.Dense(10, activation='softmax'))

model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])


model.fit(train_images, train_labels, epochs=5)

test_loss, test_acc = model.evaluate(test_images, test_labels)
print('정확도:', test_acc)
```

```
10000/10000 [=====] - 0s 32us/sample - loss: 0.3560 -
acc: 0.8701
정확도: 0.8701
```

```
test_pred=model.predict(test_images)
plt.imshow(test_images[0])
print(np.round(test_pred[0],2))
```


```
[0.  0.  0.  0.  0.  0.  0.  0.04  0.  0.96]
```



| 레이블 | 범주          |
|-----|-------------|
| 0   | T-shirt/top |
| 1   | Trouser     |
| 2   | Pullover    |
| 3   | Dress       |
| 4   | Coat        |
| 5   | Sandal      |
| 6   | Shirt       |
| 7   | Sneaker     |
| 8   | Bag         |
| 9   | Ankle boot  |

```
plt.imshow(test_images[100])  
print(np.round(test_pred[100],2))
```


```
[0. 0. 0. 1. 0. 0. 0. 0. 0. 0.]
```



| 레이블 | 범주          |
|-----|-------------|
| 0   | T-shirt/top |
| 1   | Trouser     |
| 2   | Pullover    |
| 3   | Dress       |
| 4   | Coat        |
| 5   | Sandal      |
| 6   | Shirt       |
| 7   | Sneaker     |
| 8   | Bag         |
| 9   | Ankle boot  |

```
plt.imshow(test_images[1000])  
print(np.round(test_pred[1000], 2))
```


[0.43 0. 0.05 0.02 0. 0. 0.51 0. 0. 0. ]



| 레이블 | 범주          |
|-----|-------------|
| 0   | T-shirt/top |
| 1   | Trouser     |
| 2   | Pullover    |
| 3   | Dress       |
| 4   | Coat        |
| 5   | Sandal      |
| 6   | Shirt       |
| 7   | Sneaker     |
| 8   | Bag         |
| 9   | Ankle boot  |

```
plt.imshow(test_images[2000])  
print(np.round(test_pred[2000],2))
```

```
[0. 0. 0. 0. 0. 0. 0. 0. 1. 0.]
```



| 레이블 | 범주          |
|-----|-------------|
| 0   | T-shirt/top |
| 1   | Trouser     |
| 2   | Pullover    |
| 3   | Dress       |
| 4   | Coat        |
| 5   | Sandal      |
| 6   | Shirt       |
| 7   | Sneaker     |
| 8   | Bag         |
| 9   | Ankle boot  |

과제 fasion\_org\_exam.ipynb

모델을 다음과 같이 변경 하고 code (모델 생성 부분만 )과 정확도를 제출 하시오.

1) 입력 층 : 변동 없음  
은닉층 1 : 32 ( relu)  
출력 층 변동 없음.

2) 입력 층 : 변동 없음  
은닉층 1 : 64 ( relu)  
은닉층 2 : 16 (relu)  
출력 층 변동 없음.

3) 1050번째 test이미지의 사진을 붙이고 카테고리 예측 결과를 제출 하시오

4) 615번째 test 이미지와 사진을 붙이고 카테고리 예측 결과를 제출 하시오.

```

model.add(layers.Flatten(input_shape=(28, 28)))
model.add(layers.Dense(128, activation='relu'))
model.add(layers.Dense(10, activation='softmax'))
model.summary()

```

|       |               |
|-------|---------------|
| 입력 층  | : 28 * 28     |
| 은닉층 1 | : 128 ( relu) |
| 출력 층  | : 10          |

| Layer (type)      | Output Shape | Param # |
|-------------------|--------------|---------|
| =====             |              |         |
| =====             |              |         |
| flatten (Flatten) | (None, 784)  | 0       |
| dense (Dense)     | (None, 128)  | 100480  |
| dense_1 (Dense)   | (None, 10)   | 1290    |
| =====             |              |         |
| =====             |              |         |

```
model.add(layers.Flatten(input_shape=(28, 28)))
model.add(layers.Dense(32, activation='relu'))
model.add(layers.Dense(16, activation='relu'))
model.add(layers.Dense(10, activation='softmax'))
```

입력 층 : 28 \* 28  
은닉층 1 : 32 ( relu)  
은닉층 2 : 16 ( relu)  
출력 층 : 10

| Layer (type)        | Output Shape | Param # |
|---------------------|--------------|---------|
| =====               |              |         |
| flatten_1 (Flatten) | (None, 784)  | 0       |
| dense_2 (Dense)     | (None, 32)   | 25120   |
| dense_3 (Dense)     | (None, 16)   | 528     |
| dense_4 (Dense)     | (None, 10)   | 170     |



- 데이터의 확인과 검증셋

- 먼저 데이터를 불러와 대략적인 구조를 살펴보자

```
import pandas as pd

# 깃허브에 준비된 데이터를 가져옵니다.
!git clone https://github.com/taehojo/data.git

# 와인 데이터를 불러옵니다.
df = pd.read_csv('./data/wine.csv', header=None)

# 데이터를 미리 보겠습니다.
df
```

# 케라스 신경망 실습 - 와인 종류 예측 하기

인하공전 컴퓨터 정보과

## 실행 결과

|      | 0    | 1    | 2    | 3   | 4     | 5    | 6     | 7       | 8    | 9    | 10   | 11  | 12  |
|------|------|------|------|-----|-------|------|-------|---------|------|------|------|-----|-----|
| 0    | 7.4  | 0.70 | 0.00 | 1.9 | 0.076 | 11.0 | 34.0  | 0.99780 | 3.51 | 0.56 | 9.4  | 5   | 1   |
| 1    | 7.8  | 0.88 | 0.00 | 2.6 | 0.098 | 25.0 | 67.0  | 0.99680 | 3.20 | 0.68 | 9.8  | 5   | 1   |
| 2    | 7.8  | 0.76 | 0.04 | 2.3 | 0.092 | 15.0 | 54.0  | 0.99700 | 3.26 | 0.65 | 9.8  | 5   | 1   |
| 3    | 11.2 | 0.28 | 0.56 | 1.9 | 0.075 | 17.0 | 60.0  | 0.99800 | 3.16 | 0.58 | 9.8  | 6   | 1   |
| 4    | 7.4  | 0.70 | 0.00 | 1.9 | 0.076 | 11.0 | 34.0  | 0.99780 | 3.51 | 0.56 | 9.4  | 5   | 1   |
| ...  | ...  | ...  | ...  | ... | ...   | ...  | ...   | ...     | ...  | ...  | ...  | ... | ... |
| 6492 | 6.2  | 0.21 | 0.29 | 1.6 | 0.039 | 24.0 | 92.0  | 0.99114 | 3.27 | 0.50 | 11.2 | 6   | 0   |
| 6493 | 6.6  | 0.32 | 0.36 | 8.0 | 0.047 | 57.0 | 168.0 | 0.99490 | 3.15 | 0.46 | 9.6  | 5   | 0   |
| 6494 | 6.5  | 0.24 | 0.19 | 1.2 | 0.041 | 30.0 | 111.0 | 0.99254 | 2.99 | 0.46 | 9.4  | 6   | 0   |
| 6495 | 5.5  | 0.29 | 0.30 | 1.1 | 0.022 | 20.0 | 110.0 | 0.98869 | 3.34 | 0.38 | 12.8 | 7   | 0   |
| 6496 | 6.0  | 0.21 | 0.38 | 0.8 | 0.020 | 22.0 | 98.0  | 0.98941 | 3.26 | 0.32 | 11.8 | 6   | 0   |

6497 rows × 13 columns

## ▪ 데이터의 확인과 검증셋

- 샘플이 전체 6,497개 있음
- 모두 속성이 12개 기록되어 있고 13번째 열에 클래스가 준비되어 있음
- 각 속성에 대한 정보는 다음과 같음

|   |           |    |                          |
|---|-----------|----|--------------------------|
| 0 | 주석산 농도    | 7  | 밀도                       |
| 1 | 아세트산 농도   | 8  | pH                       |
| 2 | 구연산 농도    | 9  | 황산칼륨 농도                  |
| 3 | 잔류 당분 농도  | 10 | 알코올 도수                   |
| 4 | 염화나트륨 농도  | 11 | 와인의 맛(0~10등급)            |
| 5 | 유리 아황산 농도 | 12 | 클래스(1: 레드 와인, 0: 화이트 와인) |
| 6 | 총 아황산 농도  |    |                          |

- 데이터의 확인과 검증셋


- 0~11번째 열에 해당하는 속성 12개를 X로, 13번째 열을 y로 정하겠음

```
X = df.iloc[:,0:12]
y = df.iloc[:,12]
```

- 데이터의 확인과 검증셋

- 이제 딥러닝을 실행할 차례
- 앞서 우리는 학습셋과 테스트셋을 나누는 방법에 대해 알아보았음
- 이 장에서는 여기에 검증셋을 더해 보자

▼ 그림 14-1 | 학습셋, 테스트셋, 검증셋



학습 셋 : training set  
검증 셋: validation set  
테스트 셋: test set

## ● 데이터의 확인과 검증셋

- 학습이 끝난 모델을 테스트해 보는 것이 테스트셋의 목적이라면, 최적의 학습 파라미터를 찾기 위해 학습 과정에서 사용하는 것이 검증셋
- 검증셋을 설정하면 검증셋에 테스트한 결과를 추적하면서 최적의 모델을 만들 수 있음
- 검증셋은 `model.fit()` 함수 안에 `validation_split`이라는 옵션을 주면 만들어짐
- 그림 14-1과 같이 전체의 80%를 학습셋으로 만들고 이 중 25%를 검증셋으로 하면 학습셋:검증셋:테스트셋의 비율이 60:20:20이 됨

- 데이터의 확인과 검증셋

- 전체 코드를 실행하면 다음과 같음

실습1 와인의 종류 예측하기: 데이터 확인과 실행



```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
from sklearn.model_selection import train_test_split

# 깃허브에 준비된 데이터를 가져옵니다.
!git clone https://github.com/taehojo/data.git

# 와인 데이터를 불러옵니다.
df = pd.read_csv('./data/wine.csv', header=None)
```

- 데이터의 확인과 검증셋

```
# 와인의 속성을 X로, 와인의 분류를 y로 저장합니다.  
X = df.iloc[:,0:12]  
y = df.iloc[:,12]  
  
# 학습셋과 테스트셋으로 나눕니다.  
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,  
                                                    shuffle=True)  
  
# 모델 구조를 설정합니다.  
model = Sequential()
```



- 데이터의 확인과 검증셋

```
model.add(Dense(30, input_dim=12, activation='relu'))
model.add(Dense(12, activation='relu'))
model.add(Dense(8, activation='relu'))
model.add(Dense(1, activation='sigmoid'))
model.summary()

# 모델을 컴파일합니다.
model.compile(loss='binary_crossentropy', optimizer='adam',
metrics=['accuracy'])

# 모델을 실행합니다.
history = model.fit(X_train, y_train, epochs=50, batch_size=500,
validation_split=0.25) # 0.8 x 0.25 = 0.2
```

- 데이터의 확인과 검증셋

```
# 테스트 결과를 출력합니다.  
score = model.evaluate(X_test, y_test)  
print('Test accuracy:', score[1])
```

- 데이터의 확인과 검증셋

실행 결과

Model: "sequential"

| Layer (type)    | Output Shape | Param # |
|-----------------|--------------|---------|
| =====           |              |         |
| dense (Dense)   | (None, 30)   | 390     |
| -----           |              |         |
| dense_1 (Dense) | (None, 12)   | 372     |
| -----           |              |         |
| dense_2 (Dense) | (None, 8)    | 104     |
| -----           |              |         |
| dense_3 (Dense) | (None, 1)    | 9       |
| =====           |              |         |

Total params: 875

- 데이터의 확인과 검증셋

```
Trainable params: 875
```

```
Non-trainable params: 0
```

---

```
Epoch 1/50
```

```
8/8 [=====] - 1s 23ms/step - loss: 2.9423 - accu
```

```
racy: 0.7519 - val_loss: 2.2360 - val_accuracy: 0.7562
```

```
... (중략) ...
```

```
Epoch 50/50
```

```
8/8 [=====] - 0s 6ms/step - loss: 0.1161 - accura
```

```
cy: 0.9574 - val_loss: 0.1523 - val_accuracy: 0.9500
```

- 데이터의 확인과 검증셋

```
41/41 [=====] - 0s 1ms/step - loss: 0.1438 - accu  
racy: 0.9415  
Test accuracy: 0.9415384531021118
```

## 과적합 판단

- 그래프로 과적합 확인하기

- 역전파를 50번 반복하면서 학습을 진행
- 과연 이 반복 횟수는 적절했을까?
- 학습의 반복 횟수가 너무 적으면 데이터셋의 패턴을 충분히 파악하지 못함
- 학습을 너무 많이 반복하는 것도 좋지 않음
- 너무 과한 학습은 13.2절에서 이야기한 바 있는 과적합 현상을 불러오기 때문임
- 적절한 학습 횟수를 정하기 위해서는 검증셋과 테스트셋의 결과를 그래프로 보는 것이 가장 좋음
- 이를 확인하기 위해 학습을 길게 실행해 보고 결과를 알아보자

## 실습 I 와인의 종류 예측하기: 그래프 표현



```
# 그래프 확인을 위한 긴 학습(컴퓨터 환경에 따라 시간이 다소 걸릴 수 있습니다)
history = model.fit(X_train, y_train, epochs=2000, batch_size=500,
                    validation_split=0.25)


# history에 저장된 학습 결과를 확인해 보겠습니다.
hist_df = pd.DataFrame(history.history)
hist_df

# y_vloss에 테스트셋의 오차를 저장합니다.
y_vloss = hist_df['val_loss']
```

```
# y_loss에 학습셋의 오차를 저장합니다.  
y_loss = hist_df['loss']  
  
# x 값을 지정하고 테스트셋의 오차를 빨간색으로, 학습셋의 오차를 파란색으로 표시합니다.  
x_len = np.arange(len(y_loss))  
plt.plot(x_len, y_vloss, "o", c="red", markersize=2, label='Testset_loss')  
plt.plot(x_len, y_loss, "o", c="blue", markersize=2, label='Trainset_loss')  
  
plt.legend(loc='upper right')  
plt.xlabel('epoch')  
plt.ylabel('loss')  
plt.show()
```



실행 결과



## ■ 그래프로 과적합 확인하기

- 그래프의 형태는 실행에 따라 조금씩 다를 수 있지만 대략 그림 14-2와 같은 그래프가 나옴
- 우리가 눈여겨보아야 할 부분은 학습이 오래 진행될수록 검증셋의 오차(파란색)는 줄어들이지만 테스트셋의 오차(빨간색)는 다시 커진다는 것
- 이는 과도한 학습으로 과적합이 발생했기 때문임
- 이러한 사실을 통해 알 수 있는 것은 검증셋 오차가 커지기 직 전까지 학습한 모델이 최적의 횟수로 학습한 모델이라는 것
- 이제 검증셋의 오차가 커지기 전에 학습을 자동으로 중단시키고, 그때의 모델을 저장하는 방법을 알아보자

## ● 데이터의 확인과 검증셋

- 먼저 세 개의 은닉층을 만들고 각각 30개, 12개, 8개의 노드를 만들었음
- 50번을 반복했을 때 정확도가 94.15%로 나왔음
- 꽤 높은 정확도
- 이것이 과연 최적의 결과일까?
- 이제 여기에 여러 옵션을 더해 가면서 더 나은 모델을 만들어 가는 방법을 알아보자

- 학습의 자동 중단

- 텐서플로에 포함된 케라스 API는 EarlyStopping() 함수를 제공
- 학습이 진행되어도 테스트셋 오차가 줄어들지 않으면 학습을 자동으로 멈추게 하는 함수
- 이를 조금 전 배운 ModelCheckpoint() 함수와 함께 사용해 보면

```
from tensorflow.keras.callbacks import EarlyStopping
```

```
early_stopping_callback = EarlyStopping(monitor='val_loss', patience=20)
```

## ▪ 학습의 자동 중단

- monitor 옵션은 model.fit()의 실행 결과 중 어떤 것을 이용할지 정함
- 검증셋의 오차(val\_loss)로 지정
- patience 옵션은 지정된 값이 몇 번 이상 향상되지 않으면 학습을 종료시킬지 정함
- monitor='val\_loss', patience=20이라고 지정하면 검증셋의 오차가 20번 이상 낮아지지 않을 경우 학습을 종료하라는 의미

- 학습의 자동 중단

- 모델 저장에 관한 설정은 앞 절에서 사용한 내용을 그대로 따르겠음
- 다만 이번에는 최고의 모델 하나만 저장되게끔 해 보자

```
modelpath = "./data/model/Ch14-4-bestmodel.hdf5"

checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val_loss',
verbose = 0, save_best_only=True)
```

하

## 4 학습의 자동 중단

- 학습의 자동 중단
  - 모델을 실행
  - 자동으로 최적의 에포크를 찾아 멈출 예정이므로 epochs는 넉넉하게 설정

```
history = model.fit(X_train, y_train, epochs=2000, batch_size=500,  
validation_split=0.25, verbose=1, callbacks=[early_stopping_callback,  
checkpointer])
```

## 4 학습의 자동 중단

- 학습의 자동 중단
  - 모델을 실행
  - 자동으로 최적의 에포크를 찾아 멈출 예정이므로 epochs는 넉넉하게 설정

```
history = model.fit(X_train, y_train, epochs=2000, batch_size=500,  
validation_split=0.25, verbose=1, callbacks=[early_stopping_callback,  
checkpointer])
```



- 앞서 만든 기본 코드에 다음과 같이 새로운 코드를 불러와 덧붙

```
from tensorflow.keras.callbacks import ModelCheckpoint, EarlyStopping

# 학습이 언제 자동 중단될지 설정합니다.
early_stopping_callback = EarlyStopping(monitor='val_loss', patience=20)

# 최적화 모델이 저장될 폴더와 모델 이름을 정합니다.
modelpath = "./data/model/Ch14-4-bestmodel.hdf5"

# 최적화 모델을 업데이트하고 저장합니다.
checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val_loss',
verbose=0, save_best_only=True)
```

- 학습의 자동 중단

```
# 모델을 실행합니다.  
history = model.fit(X_train, y_train, epochs=2000, batch_size=500,  
validation_split=0.25, verbose=1, callbacks=[early_stopping_callback,  
checkpointer])
```

- 학습의 자동 중단

```
# 모델을 실행합니다.  
history = model.fit(X_train, y_train, epochs=2000, batch_size=500,  
validation_split=0.25, verbose=1, callbacks=[early_stopping_callback,  
checkpointer])
```

```
1/8 [==> .....] - ETA: 0s - loss: 0.1462 - accuracy: 0.9540
Epoch 31: val_loss improved from 0.16765 to 0.16567, saving model to ./data/model/Ch14-4-bestmodel.hdf5
8/8 [=====] - 0s 9ms/step - loss: 0.1712 - accuracy: 0.9430 - val_loss: 0.1657 - val_accuracy: 0.9392
Epoch 32/2000
1/8 [==> .....] - ETA: 0s - loss: 0.2067 - accuracy: 0.9400
Epoch 32: val_loss did not improve from 0.16567
8/8 [=====] - 0s 7ms/step - loss: 0.1678 - accuracy: 0.9430 - val_loss: 0.1675 - val_accuracy: 0.9346
Epoch 33/2000
1/8 [==> .....] - ETA: 0s - loss: 0.1330 - accuracy: 0.9560
Epoch 33: val_loss did not improve from 0.16567
8/8 [=====] - 0s 6ms/step - loss: 0.1661 - accuracy: 0.9438 - val_loss: 0.1691 - val_accuracy: 0.9431
Epoch 34/2000
1/8 [==> .....] - ETA: 0s - loss: 0.1694 - accuracy: 0.9400
Epoch 34: val_loss improved from 0.16567 to 0.15903, saving model to ./data/model/Ch14-4-bestmodel.hdf5
8/8 [=====] - 0s 9ms/step - loss: 0.1694 - accuracy: 0.9418 - val_loss: 0.1590 - val_accuracy: 0.9362
Epoch 35/2000
1/8 [==> .....] - ETA: 0s - loss: 0.1949 - accuracy: 0.9380
Epoch 35: val_loss improved from 0.15903 to 0.15821, saving model to ./data/model/Ch14-4-bestmodel.hdf5
8/8 [=====] - 0s 9ms/step - loss: 0.1628 - accuracy: 0.9464 - val_loss: 0.1582 - val_accuracy: 0.9369
Epoch 36/2000
1/8 [==> .....] - ETA: 0s - loss: 0.1485 - accuracy: 0.9360
```

과제 wine.ipynb, wine.csv

wine.ipynb 를 실행 하고

- 1) model이 마지막으로 저장 되는 부분과
- 2) 학습이 종료되는 부분의 출력 결과를 붙이시오
- 3) test결과의 accuracy를 적으시오.

## ▪ 실제 데이터로 만들어 보는 모델

- 지금까지 한 실습은 참 또는 거짓을 맞히거나 여러 개의 보기 중 하나를 예측하는 분류 문제
- 이번에는 수치를 예측하는 문제
- 준비된 데이터는 아이오와주 에임스 지역에서 2006년부터 2010년까지 거래된 실제 부동산 판매 기록
- 주거 유형, 차고, 자재 및 환경에 관한 80개의 서로 다른 속성을 이용해 집의 가격을 예측해 볼 예정
- 오랜 시간 사람이 일일이 기록하다 보니 빠진 부분도 많고, 집에 따라 어떤 항목은 범위에서 너무 벗어나 있기도 하며, 또 가격과는 관계가 없는 정보가 포함되어 있기도 함
- 실제 현장에서 만나게 되는 이런 류의 데이터를 어떻게 다루어야 하는지 이 장에서 학습해 보자

- 데이터 파악하기

- 먼저 데이터를 불러와 확인해 보자

```
import pandas as pd

# 깃허브에 준비된 데이터를 가져옵니다.
!git clone https://github.com/taehojo/data.git

# 집 값 데이터를 불러옵니다.
df = pd.read_csv("./data/house_train.csv")
```

## 1 데이터 파악하기

```
import pandas as pd

# 깃허브에 준비된 데이터를 가져옵니다.
!git clone https://github.com/taehojo/data.git

# 집 값 데이터를 불러옵니다.
df = pd.read_csv("./data/house_train.csv")
```



# 케라스 신경망 실습 - 주택 가격 예측

인하공전 컴퓨터 정보과

## 실행 결과

|      | Id   | MSSubClass | MSZoning | LotFrontage | LotArea | Street | Alley | LotShape | LandContour | Utilities | ... |
|------|------|------------|----------|-------------|---------|--------|-------|----------|-------------|-----------|-----|
| 0    | 1    | 60         | RL       | 65.0        | 8450    | Pave   | NaN   | Reg      | Lvl         | AllPub    | ... |
| 1    | 2    | 20         | RL       | 80.0        | 9600    | Pave   | NaN   | Reg      | Lvl         | AllPub    | ... |
| 2    | 3    | 60         | RL       | 68.0        | 11250   | Pave   | NaN   | IR1      | Lvl         | AllPub    | ... |
| 3    | 4    | 70         | RL       | 60.0        | 9550    | Pave   | NaN   | IR1      | Lvl         | AllPub    | ... |
| 4    | 5    | 60         | RL       | 84.0        | 14260   | Pave   | NaN   | IR1      | Lvl         | AllPub    | ... |
| ...  | ...  | ...        | ...      | ...         | ...     | ...    | ...   | ...      | ...         | ...       | ... |
| 1455 | 1456 | 60         | RL       | 62.0        | 7917    | Pave   | NaN   | Reg      | Lvl         | AllPub    | ... |
| 1456 | 1457 | 20         | RL       | 85.0        | 13175   | Pave   | NaN   | Reg      | Lvl         | AllPub    | ... |
| 1457 | 1458 | 70         | RL       | 66.0        | 9042    | Pave   | NaN   | Reg      | Lvl         | AllPub    | ... |
| 1458 | 1459 | 20         | RL       | 68.0        | 9717    | Pave   | NaN   | Reg      | Lvl         | AllPub    | ... |
| 1459 | 1460 | 20         | RL       | 75.0        | 9937    | Pave   | NaN   | Reg      | Lvl         | AllPub    | ... |

| PoolArea | PoolQC | Fence | MiscFeature | MiscVal | MoSold | YrSold | SaleType | SaleCondition | SalePrice |
|----------|--------|-------|-------------|---------|--------|--------|----------|---------------|-----------|
| 0        | NaN    | NaN   | NaN         | 0       | 2      | 2008   | WD       | Normal        | 208500    |
| 0        | NaN    | NaN   | NaN         | 0       | 5      | 2007   | WD       | Normal        | 181500    |
| 0        | NaN    | NaN   | NaN         | 0       | 9      | 2008   | WD       | Normal        | 223500    |
| 0        | NaN    | NaN   | NaN         | 0       | 2      | 2006   | WD       | Abnorml       | 140000    |
| 0        | NaN    | NaN   | NaN         | 0       | 12     | 2008   | WD       | Normal        | 250000    |
| ...      | ...    | ...   | ...         | ...     | ...    | ...    | ...      | ...           | ...       |
| 0        | NaN    | NaN   | NaN         | 0       | 8      | 2007   | WD       | Normal        | 175000    |
| 0        | NaN    | MnPrv | NaN         | 0       | 2      | 2010   | WD       | Normal        | 210000    |
| 0        | NaN    | GdPrv | Shed        | 2500    | 5      | 2010   | WD       | Normal        | 266500    |
| 0        | NaN    | NaN   | NaN         | 0       | 4      | 2010   | WD       | Normal        | 142125    |
| 0        | NaN    | NaN   | NaN         | 0       | 6      | 2008   | WD       | Normal        | 147500    |

1460 rows × 81 columns

- 데이터 파악하기

- 총 80개의 속성으로 이루어져 있고 마지막 열이 우리의 타깃인 집 값(SalePrice)
- 모두 1,460개의 샘플이 들어 있음

## ■ 주택 가격 예측 모델

- 이제 앞서 구한 중요 속성을 이용해 학습셋과 테스트셋을 만들어 보자
- 집 값을 y로, 나머지 열을 X\_train\_pre로 저장한 후 전체의 80%를 학습셋으로, 20%를 테스트셋으로 지정

```
cols_train = ['OverallQual', 'GrLivArea', 'GarageCars', 'GarageArea', 'TotalBsmtSF']  
X_train_pre = df[cols_train]  
y = df['SalePrice'].values  
X_train, X_test, y_train, y_test = train_test_split(X_train_pre, y, test_size=0.2)
```

## ▪ 주택 가격 예측 모델

- 모델의 구조와 실행 옵션을 설정
- 입력될 속성의 개수를 X\_train.shape[1]로 지정해 자동으로 세도록 했음

```
model = Sequential()  
model.add(Dense(10, input_dim=X_train.shape[1], activation='relu'))  
model.add(Dense(30, activation='relu'))  
model.add(Dense(40, activation='relu'))  
model.add(Dense(1))  
model.summary()
```



- 주택 가격 예측 모델

- 실행에서 달라진 점은 손실 함수
- 선형 회귀이므로 평균 제곱 오차(mean\_squared\_error)를 적음

```
model.compile(optimizer='adam', loss='mean_squared_error')
```

## ■ 주택 가격 예측 모델

- 20번 이상 결과가 향상되지 않으면 자동으로 중단되게끔 함
- 저장될 모델 이름을 'Ch15-house.hdf5'로 정함
- 모델은 차후 '22장. 캐글로 시작하는 새로운 도전'에서 다시 사용(검증셋을 추가하고 싶을 경우 앞서와 마찬가지로 학습셋, 검증셋, 테스트셋의 비율을 각각 60%, 20%, 20%로 정하면 됨)

```
early_stopping_callback = EarlyStopping(monitor='val_loss', patience=20)

modelpath = "./data/model/Ch15-house.hdf5"

checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val_loss',
                                verbose=0, save_best_only=True)

history = model.fit(X_train, y_train, validation_split=0.25, epochs=2000,
                    batch_size=32, callbacks=[early_stopping_callback, checkpointer])
```

- 주택 가격 예측 모델

- 모든 코드를 실행하면 다음과 같음

## 실습 | 주택 가격 예측하기



```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
from tensorflow.keras.callbacks import EarlyStopping
from sklearn.model_selection import train_test_split

import matplotlib.pyplot as plt
import seaborn as sns

import pandas as pd
import numpy as np
```

```
!git clone https://github.com/taehojo/data.git
```

```
# 집 값 데이터를 불러옵니다.
```

```
df = pd.read_csv("./data/house_train.csv")
```

```
# 카테고리형 변수를 0과 1로 이루어진 변수로 바꾸어 줍니다.
```

```
df = pd.get_dummies(df)
```

```
# 결측치를 전체 칼럼의 평균으로 대체해 채워 줍니다.
```

```
df = df.fillna(df.mean())
```



```
# 데이터 사이의 상관관계를 저장합니다.
```

```
df_corr = df.corr()
```

```
# 집 값과 관련이 큰 것부터 순서대로 저장합니다.
```

```
df_corr_sort = df_corr.sort_values('SalePrice', ascending=False)
```

```
# 집 값을 제외한 나머지 열을 저장합니다.
```

```
cols_train = ['OverallQual', 'GrLivArea', 'GarageCars', 'GarageArea', 'TotalB  
smtSF']
```

```
X_train_pre = df[cols_train]
```

```
# 집 값을 저장합니다.
```

```
y = df['SalePrice'].values
```

```
# 전체의 80%를 학습셋으로, 20%를 테스트셋으로 지정합니다.
```

```
X_train, X_test, y_train, y_test = train_test_split(X_train_pre, y, test_size=0.2)
```

```
# 모델의 구조를 설정합니다.
```

```
model = Sequential()
```

```
model.add(Dense(10, input_dim=X_train.shape[1], activation='relu'))
```

```
model.add(Dense(30, activation='relu'))
```

```
model.add(Dense(40, activation='relu'))
```

```
model.add(Dense(1))
```

```
model.summary()
```

# 모델을 실행합니다.

```
model.compile(optimizer='adam', loss='mean_squared_error')
```

# 20번 이상 결과가 향상되지 않으면 자동으로 중단되게끔 합니다.

```
early_stopping_callback = EarlyStopping(monitor='val_loss', patience=20)
```

# 모델의 이름을 정합니다.

```
modelpath = "./data/model/Ch15-house.hdf5"
```

# 최적화 모델을 업데이트하고 저장합니다.

```
checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val_loss',  
verbose=0, save_best_only=True)
```

# 실행 관련 설정을 하는 부분입니다. 전체의 20%를 검증셋으로 설정합니다.

```
history = model.fit(X_train, y_train, validation_split=0.25, epochs=2000,  
batch_size=32, callbacks=[early_stopping_callback,checkpointer])
```

- 주택 가격 예측 모델

**실행 결과**

Model: "sequential"

| Layer (type)    | Output Shape | Param # |
|-----------------|--------------|---------|
| =====           |              |         |
| dense (Dense)   | (None, 10)   | 60      |
| -----           |              |         |
| dense_1 (Dense) | (None, 30)   | 330     |
| -----           |              |         |
| dense_2 (Dense) | (None, 40)   | 1240    |
| -----           |              |         |
| dense_3 (Dense) | (None, 1)    | 41      |
| =====           |              |         |

## ■ 주택 가격 예측 모델

```
Total params: 1,671
```

```
Trainable params: 1,671
```

```
Non-trainable params: 0
```

---

```
Epoch 1/2000
```

```
28/28 [=====] - 0s 5ms/step - loss:
```

```
39256875008.0000 - val_loss: 38050066432.0000
```

```
... (중략) ...
```

```
Epoch 145/2000
```

```
28/28 [=====] - 0s 2ms/step - loss:
```

```
1962943104.0000 - val_loss: 2011970944.0000
```

## ■ 주택 가격 예측 모델

- 학습 결과를 시각화하기 위해 예측 값과 실제 값, 실행 번호가 들어갈 빈 리스트를 만들고 25개의 샘플로부터 얻은 결과를 채워 넣겠음

```
real_prices = []
pred_prices = []
X_num = []

n_iter = 0
Y_prediction = model.predict(X_test).flatten()
for i in range(25):
    real = y_test[i]
    prediction = Y_prediction[i]
    print("실제가격: {:.2f}, 예상가격: {:.2f}".format(real, prediction))
    real_prices.append(real)
```

```
pred_prices.append(prediction)
n_iter = n_iter + 1
X_num.append(n_iter)
```

## ■ 주택 가격 예측 모델

### 실행 결과

실제가격: 262500.00, 예상가격: 240051.36

실제가격: 78000.00, 예상가격: 118369.56

... (중략) ...

실제가격: 127000.00, 예상가격: 116693.46

실제가격: 485000.00, 예상가격: 357789.88



실행 결과



과제 (house.ipynb, house\_train.csv )

1) 아래와 같이 모델과 학습 방법을 변경 한 후 모델을 house1.hdf5로 저장 하시오.

입력 층 : 변동 없음  
은닉층 1 : 20 ( relu)  
은닉층 2 : 20 (relu)  
은닉층 3 : 40 (relu)  
출력 층 변동 없음.

17회 이상 결과가 향상 되지 않으면 자동으로 학습이 중단되게  
Batch size 16

2) 아래와 같이 모델과 학습 방법을 변경 한 후 모델을 house2.hdf5로 저장 하시오.


입력 층 : 변동 없음  
은닉층 1 : 10 ( relu)  
은닉층 2 : 20 (relu)  
은닉층 3 : 20 (relu)  
출력 층 변동 없음.

15회 이상 결과가 향상 되지 않으면 자동으로 학습이 중단되게  
Batch size 20

[code](#) (.ppt에 직접 붙여도 되고 .py 파일로 제출 가능) 와 [model 제출](#) (house1.hdf5, hoise2.hdf5) 제출

# 영상 처리 기초


- 영상은 픽셀로 이루어짐
- 해상도 (Resolution)
  - 2차원 공간 영역에서,  $x, y$  축 방향의 픽셀들의 개수



# 영상 처리 기초 – Open CV 실습

본인이 찍어온 사진 or test1\_1920.jpg 사용

본인이 찍어온 사진 크기 조정 => 1920x1440 과 비슷한 크기로



# 영상 처리 기초 – Open CV 실습

Colab에서 실습

```
import cv2
from google.colab.patches import cv2_imshow  ## colab일 경우만 필요
img=cv2.imread( ' /content/test1_1920.jpg')
print('img.ndim = ',img.ndim)
print('img.shape = ',img.shape)
print('img.dtype = ',img.dtype)
```

# 영상 처리 기초 – Open CV 실습

Colab에서 실습

```
import cv2
from google.colab.patches import cv2_imshow  ## colab일 경우만 필요
img=cv2.imread( ' /content/test1_1920.jpg')
print('img.ndim = ',img.ndim)
print('img.shape = ',img.shape)
print('img.dtype = ',img.dtype)
```

```
img.ndim = 3
img.shape = (1440, 1920, 3)
img.dtype = uint8
```

# 영상 처리 기초 – Open CV 실습

Colab에서 실습

#colab

```
cv2_imshow(img)
```

```
cv2.imshow
```

# 영상 처리 기초 – Open CV 실습

Colab에서 실습

```
img=cv2.resize(img, (0,0) ,fx=0.5,fy=0.5)
cv2.imwrite('test1_half.jpg',img)
print(img.shape)
```



# 영상 처리 기초 – Open CV 실습

Colab에서 실습

```
img=cv2.resize(img, (0,0) ,fx=0.5,fy=0.5)  
cv2.imwrite('test1_half.jpg',img)  
print(img.shape)
```

```
img.shape = (720, 960, 3)
```

# 영상 처리 기초 – Open CV 실습

Colab에서 실습

```
img=cv2.resize(img, (0,0) ,fx=0.5,fy=0.5)  
cv2.imwrite('test1_half.jpg',img)  
print(img.shape)
```

영상 변형

# 영상 처리 기초 – Open CV 실습

```
img1=cv2.imread('/content/test1_half.jpg')
gimg = cv2.cvtColor(img1, cv2.COLOR_BGR2GRAY)
cv2.imwrite('test1_halfgray.jpg',gimg)

print(gimg.shape)
imshow(gimg)
```

# 영상 처리 기초 – Open CV 실습


```
img1=cv2.imread('/content/test1_half.jpg')
gimg = cv2.cvtColor(img1, cv2.COLOR_BGR2GRAY)
cv2.imwrite('test1_halfgray.jpg',gimg)

print(gimg.shape)
imshow(gimg)
```

(720, 960)


# 영상 처리 기초

- 영상은 픽셀로 이루어짐
- 해상도 (Resolution)
  - 2차원 공간 영역에서,  $x, y$  축 방향의 픽셀들의 개수



# 영상 처리 기초

- 영상은 픽셀로 이루어짐.
- RGB color space
  - Red, Green, Blue



Img.shape

=(height, width, rgb==3)

Pixel of an RGB image are formed from the corresponding pixel of the three component images

# 영상 처리 기초



컬러 이미지

`Img.shape`

`=(height, width, rgb==3)`



그레이 이미지

`Img.shape`

`=(height, width)`

$$\text{Gray} = 0.299 * R + 0.587 * G + 0.114 * B$$

# 수고 하셨습니다



[jhmin@inhatec.ac.kr](mailto:jhmin@inhatec.ac.kr)